

<!-- modèle : llama3.1:latest | source : anglais → français | chapitres traduits : 7, 8 -->

<!-- === chapitre 7 : Chapter 3: Learning to Compute === -->

****Apprendre à calculer****

****McCulloch-Pitts, le Perceptron et les réseaux de neurones artificiels****

Le mathématicien de l'Université de Cambridge Bertrand Russell a passé 10 ans au début du vingtième siècle pour travailler vers un objectif monumental : identifier les racines philosophiques d'où tout la mathématique provient. Entrepris en collaboration avec son ancien professeur Alfred Whitehead, ce projet ambitieux a produit un livre, le *_Principia Mathematica_*, qui a été remis aux éditeurs en retard et au-dessus du budget. Les auteurs eux-mêmes ont dû contribuer vers les coûts de publication pour que cela se fasse et ils n'ont pas vu de royalties pendant 40 ans.

Mais l'obstacle financier fut peut-être le plus petit à surmonter pour terminer cet ouvrage. Russell devait lutter contre son agitation face aux matériaux universitaires. Selon son autobiographie, il passa des jours à fixer un feuillet blanc et les soirées à réfléchir à la possibilité de sauter devant un train. Le travail sur le livre coïncidait également avec la dissolution du mariage de Russell et une tension dans sa relation avec Whitehead – qui, selon Russell, se battait lui-même contre des batailles mentales et conjugales à l'époque. Le livre était même physiquement exigeant : Russell passa 12 heures par jour à un bureau pour écrire les symboles complexes nécessaires à la transmission de ses idées mathématiques complexes et lorsque le moment vint de présenter le manuscrit au publier, il était trop grand pour qu'il puisse le porter. Malgré tout, Russell et Whitehead terminèrent et publièrent finalement le texte qu'ils espéraient calmer l'état sauvage qui semblait régner en mathématiques.

La thèse du *_Principia_* consistait à réduire toute la mathématique à la logique. En d'autres termes, Russell et Whitehead croyaient qu'une poignée de

Déclarations de base, appelées « expressions », pourraient être combinées d'une manière juste pour générer toutes les formalismes, affirmations et découvertes des mathématiciens. Ces expressions n'étaient pas issues d'observations du monde réel. Au contraire, elles étaient censées être universelles. Par exemple, l'expression : si X est vrai, alors la déclaration « X est vrai ou Y est vrai » est également vraie. De telles expressions sont constituées de propositions : des unités fondamentales de logique qui peuvent être soit vraies, soit fausses, écrites comme des lettres telles que X ou Y. Ces propositions sont liées entre elles avec des opérateurs « Boolean »¹ tels que « et », « ou » et « pas ».

Dans le premier volume du *Principia*, Russell et Whitehead ont fourni moins de deux douzaines de ces expressions abstraites. À partir de ces germes modestes, ils ont bâti la mathématique. Ils étaient même en mesure de conclure triomphalement – après des dizaines de pages remplies de symboles – que $1+1=2$.

La démonstration par Russell et Whitehead selon laquelle la grandeur complète de la mathématique pouvait être capturée avec les règles simples de logique² a eu des implications philosophiques immenses car elle a fourni une preuve du pouvoir de la logique. De plus, cela signifiait que une découverte ultérieure, faite par un autre couple d'hommes il y a 30 ans, aurait des implications immenses. Cette découverte disait que les neurones, simplement via la nature de leur anatomie et physiologie, mettaient en œuvre les règles de logique. Cela a révolutionné l'étude du cerveau et de l'intelligence elle-même.

Quand le natif de Détroit Walter Pitts n'avait que 12 ans, il fut invité par Russell à rejoindre comme étudiant diplômé l'Université de Cambridge. Le jeune garçon avait, selon la légende, rencontré une copie des *Principia* après avoir couru dans une bibliothèque pour éviter les brutes. Alors qu'il lisait, Pitts a trouvé ce qu'il croyait être des erreurs dans l'ouvrage. Il a donc envoyé ses notes sur le sujet à Russell, qui, probablement ignorant de l'âge du garçon, lui a alors offert la position. Pitts n'a pas accepté. Mais quelques années plus tard, lorsque Russell était en visite à l'Université de Chicago, Pitts est allé assister à ses conférences. Ayant fui une maison familiale abusive pour venir à Chicago, Pitts a décidé de ne pas y retourner. Il est resté dans la ville, sans abri.

Heureusement, l'Université de Chicago avait un autre logicien mondialement célèbre pour que Pitts puisse critiquer – Rudolf Carnap. Cette fois encore, Pitts a rédigé des notes – cette fois identifiant des problèmes dans le livre récent de Carnap *La Syntaxe Logique du Langage* – et les a remises à l'office de Carnap à l'Université de Chicago. Pitts n'a pas resté longtemps pour entendre sa réaction, mais Carnap, impressionné, a fini par poursuivre Pitts, qu'il appelait « ce petit journalier qui comprenait la logique ». Cette fois-ci, le philosophe qu'il critiquait a réussi à faire travailler avec lui. Même s'il n'a jamais officiellement inscrit, Pitts a fonctionné efficacement comme étudiant diplômé pour Carnap et fraternisé avec un groupe de chercheurs intéressés par les mathématiques de la biologie.

L'intérêt de Warren McCulloch pour la philosophie prit une forme plus traditionnelle. Né dans le New Jersey, il étudia ce sujet (ainsi que la psychologie) à Yale et lut beaucoup des grands auteurs. Il était particulièrement fasciné par Immanuel Kant et Gottfried Leibniz (dont les idées étaient très influentes pour Russell), et il lut le *Principia* à l'âge de 25 ans. Mais, malgré la barbe sur son long visage, McCulloch n'était pas un philosophe – il était un physiologiste. Il fréquenta une école de médecine à Manhattan et alla ensuite observer les multiples façons dont le cerveau peut se briser en tant qu'interne en neurologie au Bellevue Hospital et à la Rockland State Hospital, un établissement psychiatrique. En 1941, il rejoignit l'université de l'Illinois à Chicago en tant que directeur du laboratoire de recherche fondamentale dans le département de psychiatrie.

Comme toutes les grandes histoires d'origine, il y a des comptes contradictoires sur la manière dont McCulloch et Pitts se sont rencontrés. L'un prétend qu'il s'est produit lorsque McCulloch a parlé devant un groupe de recherche auquel Pitts faisait partie. Une autre histoire est que Carnap les a présentés l'un à l'autre. Finalement, un contemporain des deux hommes, Jerome Lettvin, affirma qu'il les avait présentés et que tous trois s'étaient liés par leur amour commun de Leibniz. Dans tous les cas, en 1942, le 43 ans McCulloch et son épouse avaient pris Pitts âgé de 18 ans chez eux, et les deux hommes passaient leurs soirées à boire du whisky et à discuter de logique.

La barrière entre l'« esprit » et le « corps » était forte parmi les scientifiques au début du vingtième siècle. L'esprit était considéré comme intérieur et intangible ; le corps, y compris le cerveau, était physique. Les chercheurs de chaque côté de cette barrière travaillaient avec diligence, mais séparément, à leurs propres problèmes. Les biologistes, comme nous l'avons vu dans le dernier chapitre, travaillaient dur pour découvrir la machinerie physique des neurones : en utilisant des pipettes et des électrodes et des substances chimiques pour déterminer ce qui provoque une impulsion et comment faire cela. Les psychiatres, d'un autre côté, tentaient de découvrir la machinerie de l'esprit grâce à des séances longues de psychoanalyse freudienne. Peu du côté gauche ou du côté droit essaieraient un regard sur l'autre en passant par la barrière. Ils parlaient des langages séparés et travaillaient vers des objectifs différents. Pour la plupart des praticiens, la question de savoir comment les blocs de construction neuroniques pouvaient créer la structure de l'esprit n'était pas seulement sans réponse, mais aussi non posée.

Mais McCulloch, dès le début de sa formation médicale, s'était immergé dans un groupe de scientifiques qui se souciaient de cette question et lui avaient laissé l'espace pour y réfléchir. Finalement, grâce à ses observations physiologiques, il eut une intuition. Il vit dans les concepts émergents de la neurosciences un possible mappage des notions de logique et de calcul qu'il adorait en philosophie. Penser au cerveau comme un dispositif informatique suivant les règles de la logique – plutôt que juste un sac de protéines et de composés chimiques – ouvrirait la porte à comprendre le penser en termes d'activité neuronale.

La capacité analytique, cependant, n'était pas là où McCulloch excellait. Certains qui le connaissaient disaient qu'il était trop romantique pour être retenu par de tels détails. Ainsi, malgré des années de jeux d'idées dans sa tête et en conversation (même comme interne à Bellevue il fut accusé de « tenter d'écrire une équation pour le fonctionnement du cerveau »), McCulloch lutta avec plusieurs problèmes techniques sur la façon d'y parvenir. Pitts, cependant, était comparativement indifférent à l'analytique. Dès qu'il en parla avec lui, Pitts vit ce qui était nécessaire pour formaliser les intuitions de McCulloch. Pas longtemps après qu'ils se soient rencontrés, l'un des papiers les plus influents sur la computation a été écrit.

« Un calcul logique des idées immanentes dans l'activité nerveuse » a été publié en 1943. Le papier compte 17 pages avec de nombreuses équations, trois références (dont une au *Principia*) et une seule figure constituée de petits circuits neuronaux dessinés par la fille de McCulloch³.

Le papier commence par passer en revue la biologie des neurones qui était connue à l'époque : les neurones ont des corps cellulaires et des axones ; deux neurones se connectent lorsque l'axon du premier rencontre le corps du second ; grâce à cette connexion, un neurone fournit une entrée à l'autre ; il faut une certaine quantité d'entrées pour que le neurone fasse feu ; une cellule fait feu ou ne fait pas feu – pas de demi-éclaircs ni d'éclaircs intermédiaires ; et les entrées provenant de certains neurones – des neurones inhibiteurs – ont la capacité de prévenir qu'une cellule ne fasse pas feu.

McCulloch et Pitts expliquent ensuite comment ces détails biologiques sont congruents avec la logique binaire. Le noyau de leur affirmation est que l'état d'activité de chaque neurone – soit il fait feu, soit il ne fait pas feu – ressemble à la valeur de vérité d'une proposition – soit vrai ou faux. Dans leurs propres mots, ils « conçoivent la réponse de tout neurone comme étant factuellement équivalente à une proposition qui propose son stimulus adéquat ».

En parlant de « son stimulus adéquat », ils se réfèrent à quelque chose du monde. Imaginez un neurone dans le cortex visuel dont l'activité représente la déclaration « le stimulus visuel actuel ressemble à un canard ». Si ce neurone est en feu, cette déclaration est vraie ; si le neurone n'est pas en feu, elle est fausse.

Imaginez maintenant un autre neurone dans le cortex auditif qui représente la déclaration « le stimulus auditif actuel émet un bruit de canard ». Encore une fois, si ce neurone est en feu, cette déclaration est vraie ; sinon, elle est fausse.

Maintenant, nous pouvons utiliser les connexions entre les neurones pour mettre en œuvre des opérations booléennes. Par exemple, en donnant à un troisième neurone des entrées provenant de ces deux neurones, on pourrait mettre en œuvre la règle « si cela ressemble à un canard et il émet le bruit d'un canard, c'est un canard ». Il suffit de construire le troisième neurone pour qu'il ne fasse feu que si les deux neurones d'entrée sont en feu. De cette façon, « cela ressemble à un canard » et « il émet le bruit d'un canard » doivent être vrais pour que la conclusion représentée par le troisième neurone (« c'est un canard ») soit vraie.

Cette description décrit le circuit simple nécessaire pour mettre en œuvre l'opération booléenne 'et'. McCulloch et Pitts dans leur papier montrent comment mettre en œuvre de nombreuses autres. Pour mettre en œuvre 'ou' est très similaire, cependant la force des connexions provenant de chaque neurone doit être si forte que l'un seul entrée suffit à faire feu le neurone de sortie. Dans ce cas, le neurone ou 'est un canard' ferait feu si le neurone 'semble un canard' ou le neurone 'fait comme un canard' (ou les deux) étaient en train de fonctionner. Les auteurs montrent même comment relier ensemble plusieurs opérations booléennes. Par exemple, pour mettre en œuvre une déclaration comme 'X et non Y', le neurone représentant X se connecte à un neurone de sortie avec une force suffisante pour qu'il fasse feu. Mais le neurone représentant Y inhibe le neurone de sortie, ce qui signifie qu'il l'empêche de faire feu. De cette façon, le neurone de sortie ne fera feu que si le neurone représentant X est en train de fonctionner et le neurone représentant Y n'est pas (voir la figure 4).

Ces circuits, qui sont censés représenter ce que les réseaux de vrais neurones peuvent faire, sont devenus connus sous le nom de réseaux de neurones artificiels.

Si le neurone Z a besoin de 2 entrées pour fonctionner, il représentera...

```
... X et Y ..X ou Y
PO Force d'entrée
aa =k
>>ie
... X et non Y
```

Cela signifie que la population de neurones peut effectuer des calculs infinis : interpréter les entrées sensorielles, développer des conclusions, former des plans, raisonner à travers des arguments, effectuer des calculs et ainsi de suite.

Avec ce pas dans leur recherche, McCulloch et Pitts ont avancé l'étude de la pensée humaine et, en même temps, l'ont renversée. Le « cerveau » a perdu son statut de mystérieux et d'éthéré une fois qu'il a été ramené à terre solide – c'est-à-dire une fois que ses grandes capacités ont été réduites au tir des neurones. Pour adapter un quote de Lettvin, le cerveau pouvait maintenant être considéré comme « une machine, charnelle et miraculeuse, mais toujours une machine ». Plus hardiment encore, l'élève de McCulloch, Michael Arbib, a remarqué plus tard que le travail « a tué le dualisme ».

Russell était connu pour se plaindre que, malgré les 20 ans qu'il y avait mis et l'impact qu'il avait eu sur les logiciens et les philosophes, le *_Principia_* n'avait pas d'effet sur les mathématiciens pratiquants. Sa nouvelle approche des fondements de la mathématique ne semblait tout simplement pas signifier grand-chose pour ceux qui faisaient de la mathématique ; elle n'affectait pas leur travail quotidien. La même chose pouvait être dite de la découverte de McCulloch et Pitts pour les neuroscientifiques de l'époque. Les biologistes, physiologistes, anatomistes – les scientifiques qui faisaient le travail physique de miner les neurones pour déterminer leurs mécanismes – n'ont pas pris grand-chose à la théorie. Cela était en partie dû au fait qu'il ne s'était pas avéré évident quelles expériences devaient suivre de là. Mais cela peut également avoir été dû au notation technique très technique du papier et à son style d'écriture moins que convivial. Dans une critique sur la conduction nerveuse écrite trois ans plus tard, l'auteur fait référence au papier McCulloch-Pitts comme « pas pour le lecteur de base » et remarque qu'il est nécessaire que les physiologistes s'habituent à la technologie mathématique ou que les mathématiciens exposent leurs conclusions en un langage moins imposant. La barrière entre l'esprit et le corps peut avoir été abattue, mais celle entre biologiste et mathématicien restait solide.

Il y avait un groupe séparé de personnes – un groupe avec la connaissance technique requise – qui s'intéressaient au calcul logique des neurones. Dans l'ère post-guerre, une série de réunions organisées par la fondation philanthropique Macy rassemblèrent biologistes et techniciens, dont beaucoup souhaitaient utiliser les découvertes biologiques pour construire des machines ressemblant à un cerveau. McCulloch était l'un des organisateurs de ces réunions, et les participants comprenaient le « père de la cybernétique » Norbert Wiener et John von Neumann, inventeur de l'architecture informatique moderne, qui a été directement inspiré dans sa conception par les neurones McCulloch-Pitts. Comme l'a décrit Lettvin 40 ans plus tard : « Le tout le domaine de la neurologie et de la neurobiologie a ignoré la structure, le message et la forme de la théorie de McCulloch et Pitts. Au lieu de cela, ceux qui y étaient inspirés étaient ceux qui allaient devenir les aficionados d'une nouvelle entreprise, maintenant appelée Intelligence Artificielle ».

L'armée américaine a démontré dernièrement l'embryon d'un ordinateur électronique nommé le Perceptron, qui, lorsqu'il sera complété dans environ un an, est prévu pour être la première mécanisme non vivant capable de « percevoir, reconnaître et identifier ses alentours sans formation ou contrôle humain ». [...]

“Le Dr Frank Rosenblatt, psychologue de recherche au Laboratoire Aéronautique Cornell, Inc., Buffalo, NY, concepteur du Perceptron, a mené la démonstration. L'appareil, a-t-il dit, serait le premier dispositif électronique à penser comme le cerveau humain. Comme les humains, le Perceptron fera des erreurs au début, ‘mais il deviendra plus sage avec l'expérience’, a-t-il ajouté.”

Cette synthèse, issue d'un article intitulé « L'« encéphale » électronique s'apprend lui-même », est apparue dans le numéro du 13 juillet 1958 du *New York Times*, en face d'une lettre à l'édition sur le débat en cours sur la question de savoir si fumer cause le cancer. Frank Rosenblatt, l'architecte de 30 ans du projet, allait au-delà de sa formation en psychologie expérimentale pour construire un ordinateur capable de rivaliser avec les technologies les plus avancées de l'époque.

L'ordinateur en question était plus haut que les ingénieurs qui l'opéraient et environ deux fois aussi long. Il était recouvert à chaque extrémité de panneaux de contrôle et de mécanismes de lecture. Rosenblatt a demandé les services de trois 'personnes professionnelles' et d'un personnel technique associé pendant 18 mois pour le construire, et l'estimation du coût était de 100 000 \$ (environ 870 000 \$ aujourd'hui). Le mot « perceptron », défini par Rosenblatt, est un terme générique désignant une certaine classe de dispositifs capables de 'reconnaître des similarités ou des identités entre des modèles d'informations optiques, électriques ou tonales'. Le Perceptron – l'ordinateur construit en 1958 – était donc techniquement une sous-classe connue comme

Un 'photopercéptron' car il prenait comme entrée l'output d'une caméra montée sur un trépied à une extrémité de la machine.

Le Perceptron était, tout comme les modèles introduits dans le papier McCullochPitts, un réseau de neurones artificiel. Il s'agissait d'une réplique simplifiée de ce que font et comment se connectent les vrais neurones. Mais au lieu de rester une construction mathématique qui n'existe que sous forme d'encre sur une page, le Perceptron a été physiquement réalisé. La caméra fournissait 400 entrées à ce réseau sous la forme d'une grille 20x20 de capteurs de lumière. Des câbles ont ensuite connecté au hasard l'output de ces capteurs aux unités d'association – petits circuits électriques qui additionnaient leurs entrées et basculaient en 'allumé' ou 'éteint' comme résultat, tout comme un neurone. L'output de ces unités d'association est devenu l'entrée des unités de réponse, qui elles-mêmes pouvaient être 'allumées' ou 'éteintes'. Le nombre d'unités de réponse était égal au nombre de catégories mutuellement exclusives à laquelle une image pouvait appartenir. Par exemple, si l'US Navy voulait utiliser le Perceptron pour déterminer si un avion était présent dans une image ou non, il y aurait deux unités de réponse : une pour les avions et une pour pas d'avion. À l'autre extrémité de la machine se trouvait un ensemble de lampes qui indiquaient à l'ingénieur laquelle des unités de réponse était active – c'est-à-dire, quelle catégorie l'entrée appartenait.

Mettre en œuvre un réseau de neurones artificiel de cette manière était grand et fastidieux, plein de commutateurs, de connecteurs et de tubes à gaz. Le même réseau composé de vraies neurones serait plus petit qu'une graine de sel de mer. Mais la mise en œuvre physique était importante. Cela signifiait que les théories sur la façon dont les neurones calculaient pouvaient être testées dans le monde réel sur des données réelles. Alors que le travail de McCulloch-Pitts était à propos de prouver un point en théorie, le Perceptron l'a mis en pratique.

Une autre différence importante entre le Perceptron et le réseau McCulloch-Pitts était que, comme le disait Rosenblatt au *New York Times*, le Perceptron apprend. Dans le papier de McCulloch et Pitts, les auteurs ne font aucune référence à la façon dont la connectivité entre les neurones se fait. C'est simplement défini en fonction de la fonction logique que le réseau doit exécuter et il reste ainsi. Pour que le Perceptron apprenne, cependant, il doit modifier ses connexions.

En fait, le Perceptron dérive toute sa fonctionnalité du changement de forces de ses connexions jusqu'à ce qu'elles soient juste.

Le type d'apprentissage auquel s'engage le Perceptron est appelé « apprentissage supervisé ». En fournissant des paires d'entrées et de sorties – disons, une série d'images et si elles contiennent ou non un jet – le Perceptron apprend à prendre cette décision par lui-même. Il le fait en changeant la force des connexions – également appelée « poids » – entre les unités associatives et les sorties.

Spécifiquement, lorsqu'une image est fournie au réseau, il active d'abord les unités dans la couche d'entrée, puis dans la couche de liaison et enfin dans la couche de lecture, indiquant la décision du réseau. Si le réseau commet une erreur de classification, les poids changent selon ces règles :

1. Si une unité de lecture est « éteinte » quand elle devrait être « allumée », les connexions des unités de liaison « allumées » vers cette unité de lecture sont *renforcées*.
2. Si une unité de lecture est « allumée » quand elle devrait être « éteinte », les connexions des unités de liaison « allumées » vers cette unité de lecture sont *affaiblies*.

En suivant ces règles, le réseau commencera à associer correctement les images avec la catégorie dont elles font partie. Si le réseau peut apprendre à le faire bien, il arrêtera de commettre d'erreurs et les poids cesseront de changer.

Cette procédure d'apprentissage était, de nombreux points de vue, la partie la plus remarquable du Perceptron. C'était la clé conceptuelle qui pouvait ouvrir toutes les portes. Au lieu de devoir dire à un ordinateur exactement comment résoudre un problème, il suffisait de lui montrer quelques exemples de ce problème résolu. Cela avait le potentiel de révolutionner l'informatique et Rosenblatt n'était pas timide pour le dire. Il a déclaré au *New York Times* que les Perceptrons seraient « capables de reconnaître des personnes et d'appeler leurs noms » et « capables d'entendre une langue parlée et traduire instantanément en parole ou en écriture dans une autre langue ». Il a également ajouté qu'il serait possible de construire des Perceptrons qui pourraient se reproduire en ligne de montage et qui seraient "conscients" de leur existence". Cette déclaration était audacieuse, au moins, et personne n'était heureux avec la bravade publique de Rosenblatt. Mais l'esprit de la revendication – qu'un ordinateur capable d'apprendre accélérerait la résolution presque tout problème – sonnait vrai.

La puissance de l'apprentissage, cependant, venait à un prix. Laisser le système décider sa propre connectivité avait effectivement divorcé ces connexions du concept d'opérateurs Boolean. Le réseau *pouvait* apprendre la connectivité qui

etc. Mais McCulloch et Pitts avaient identifié comme nécessaires pour 'et', 'ou' que le système ne l'exige pas, ni n'a besoin de comprendre le système sous cet angle. De plus, tandis que les unités d'association dans la machine Perceptron étaient conçues pour être uniquement 'allumé' ou 'éteint', la règle d'apprentissage ne nécessite en fait pas qu'elles soient ainsi. En fait, le niveau d'activité de ces neurones artificiels pourrait être n'importe quel nombre positif et la règle fonctionnerait toujours.⁵ Cela rend le système plus flexible, mais sans une réponse binaire 'allumé'-'éteint', cela rend-il plus difficile de cartographier l'activité de ces unités aux valeurs logiques binaires des propositions. En comparaison avec la logique claire et nette des réseaux McCulloch-Pitts, le Perceptron était un chaos ininterprétable. Mais il fonctionnait. L'interprétabilité a été sacrifiée pour l'aptitude.

Le machine Perceptron et sa procédure d'apprentissage associée sont devenus un objet de recherche populaire dans le domaine en plein essor de l'intelligence artificielle. Lorsqu'il a fait la transition d'un objet physique spécifique (le Perceptron) à une notion mathématique abstraite (l'algorithme perceptron), les couches d'entrée et d'association ont été supprimées séparément. Au lieu de cela, les unités d'entrée représentant les données entrantes se connectaient directement aux unités de lecture et, par l'apprentissage, ces connexions changeaient pour rendre le réseau meilleur à sa tâche. Comment et ce que le perceptron dans cette forme simplifiée pouvait apprendre a été étudié sous tous les angles. Les chercheurs ont exploré ses mécanismes mathématiquement en utilisant la plume et le papier, ou physiquement en construisant leur propre machine Perceptron, ou – lorsque les ordinateurs numériques sont finalement devenus disponibles – électroniquement en simulant.

Le perceptron a généré l'espoir que les humains pourraient construire des machines qui apprennent comme nous le faisons ; de cette manière, il a mis la perspective de l'intelligence artificielle à portée de main. Simultanément, il a fourni une nouvelle façon d'aborder notre propre intelligence. Il a montré que les réseaux neuronaux artificiels pouvaient calculer sans se conformer aux règles strictes de la logique. Si le perceptron peut percevoir sans l'utilisation de propositions ou d'opérateurs, il s'ensuit que chaque neurone et connexion dans le cerveau n'a pas besoin avoir un rôle clair en termes de logique binaire. Au lieu de cela, le cerveau pourrait fonctionner de manière plus imprécise, où, comme le perceptron, la fonction d'un réseau est répartie sur ses neurones et émerge des connexions entre eux. Cette nouvelle approche de l'étude du cerveau est devenue connue sous le nom de « connexionnisme ».

Le travail de McCulloch et Pitts était une pierre angulaire importante. Comme la première démonstration de la manière dont les réseaux de neurones pouvaient penser, il a été responsable du fait que la neurosciences s'éloignaient des rives de la biologie pure et plongeait dans l'océan de la computation. Ce fait, plutôt que la véracité de ses revendications, est ce qui lui donne sa place dans l'histoire. L'ancêtre intellectuel du travail de McCulloch et Pitts, le *Principia Mathematica*, pourrait être dit avoir souffert d'un sort similaire. En 1931, le mathématicien allemand Kurt Gödel a publié « Sur les propositions formellement indécidables du *Principia Mathematica* et des systèmes connexes ». Ce papier a pris le *Principia Mathematica* comme point de départ pour montrer pourquoi son objectif même – expliquer toute la mathématique à partir de prémisses simples – était impossible à atteindre. Russell et Whitehead n'avaient pas, en fait, réalisé ce qu'ils croyaient avoir fait.⁶ Les découvertes de Gödel sont devenues connues sous le nom de « théorème d'incomplétude » et ont eu un effet révolutionnaire sur la mathématique et la philosophie. Un effet qui a été en partie causé par l'échec de l'essai de Russell et Whitehead.

Russell et McCulloch ont réussi à prendre en compte les échecs de leurs travaux respectifs dans leur stride. Pitts, d'un autre côté, était fait de tissu plus fin. La réalisation que le cerveau ne mettait pas en œuvre les belles règles de la logique l'a déchiré en deux.⁷ Cela, ainsi que des difficultés mentales préexistantes et la fin d'une relation avec un mentor important, l'a poussé à boire et à expérimenter d'autres drogues. Il est devenu erratique et délirant ; il a brûlé son travail et s'est retiré de ses amis. Il est décédé des impacts de la maladie du foie en 1969 – l'année même où McCulloch est décédé. McCulloch avait 70 ans ; Pitts avait 46 ans.

<!-- Début du texte de l'image -->

Perceptron Cerebellum
connections Lecture rn
Page
: : A
zones:

apprenti ERAN ed OA
trom erreurs" ; wy € Purkinje cell
\
poePe FbaleP wQyaly ly @ [lecture/
er ae .
'9 50° 00 Fibre de
montée
fibre d'entrée
Climbing Granule. [cellules d'erreur]
= ooff
jentrée/
@ =on
<!-- Fin du texte de l'image -->

Dans sa façon tortueuse et organique, la circulation du cervelet possède une organisation et une précision dénuées de biologie. C'est dans ce branchage biologique que James Albus, un étudiant en doctorat en génie électrique travaillant à NASA, a vu les principes du perceptron en jeu.

Le cervelet joue un rôle crucial dans le contrôle moteur ; il aide à la balance, à la coordination, aux réflexes et plus encore. L'un des aspects les plus étudiés de ses capacités est la conditionnement du clignement d'œil. Il s'agit d'un réflexe entraîné qui peut être trouvé dans la vie quotidienne. Par exemple, si un parent ou colocataire déterminé tente de vous faire sortir du lit le matin en tirant les rideaux, vous ferrez instinctivement la fermeture des yeux en réponse à la lumière du soleil. Après quelques jours, simplement le son des rideaux qui s'ouvrent peut suffire pour que vous cligniez des yeux en anticipation.

Dans le laboratoire, ce processus est étudié sur les lapins et la lumière intrusive est remplacée par une petite bouffée d'air dans l'œil (juste assez gênante pour s'assurer qu'ils voudront l'éviter). Après plusieurs essais de jouer un son (comme un bref éclat d'une pure tonalité) et le suivre par cette petite bouffée d'air, le lapin apprend finalement à fermer les yeux immédiatement en entendant la tonalité. Jouez au animal un nouveau son (par exemple, un bruit de claques) qui n'a pas été associé aux bouffées d'air et il ne clignera pas. Cela rend le conditionnement du clignement d'œil une tâche de classification simple : le lapin doit décider si un son qu'il entend est indicatif d'une bouffée d'air imminente (dans ce cas, les yeux doivent se fermer) ou s'il s'agit d'un bruit neutre (dans ce cas ils peuvent rester ouverts). Lorsque le cervelet est perturbé, les lapins ne peuvent pas apprendre cette tâche.

Les cellules de Purkinje ont le pouvoir de fermer les yeux. En particulier, une baisse de leur taux de décharge normalement élevé entraînera, via des connexions qu'elles envoient à partir de cette zone, la fermeture des yeux. Sur la base d'anatomie, Albus a vu leur rôle comme le résultat de lecture – c'est-à-dire qu'ils indiquent le résultat de la classification.

Le perceptron apprend par supervision : il lui faut des entrées et des étiquettes pour ces entrées afin de savoir quand il s'est trompé. Albus a vu ces deux fonctions dans les deux types de connexions sur les cellules de Purkinje. Les cellules granulaires transmettent les signaux sensoriels ; spécifiquement, différentes cellules granulaires déclenchent en fonction du son qui est joué. Les fibres grimpantes indiquent au cervelet l'air pincé ; elles déclenchent lorsque cette gêne est ressentie. Importamment, cela signifie que les fibres grimpantes signalent une erreur. Elles indiquent que l'animal s'est trompé en ne fermant pas ses yeux quand il aurait dû le faire.

Pour éviter cette erreur, les connexions entre les cellules granulaires et les cellules de Purkinje doivent changer. En particulier, Albus anticipait que toute cellule granulaire qui était active avant l'activation du fibre de grimpe (*_c'est-à-dire_* , avant une erreur), devrait affaiblir sa connexion à la cellule de Purkinje. De cette façon, la prochaine fois que ces cellules granulaires déclenchent – *_c'est-à-dire_* , la prochaine fois que le même son est joué – elles *_ne_* ne déclencheront pas les cellules de Purkinje. Et ce creux dans l'activité des cellules de Purkinje *_causera_* que les yeux se ferment. Par cette modification des forces de connexion, l'animal apprend à ses erreurs passées et évite les puffs d'air futurs vers l'œil.

De cette façon, la cellule de Purkinje agit comme un président conseillé par une cabine de conseillers granulaires. Au début, la cellule de Purkinje écoute tous les conseils. Mais si c'est clair que certains donnent des conseils mauvais – *_c'est-à-dire_* , leur entrée est suivie d'une nouvelle négative délivrée par le fibre de grimpe – leur influence sur la cellule de Purkinje faiblira. Et la cellule de Purkinje agira mieux à l'avenir. C'est un processus qui reflète directement la règle d'apprentissage du perceptron.

Lorsque Albus a proposé cette cartographie entre le perceptron et le cervelet en 1971,⁸ sa prédiction sur la façon dont les connexions entre les cellules granulaires et les cellules de Purkinje devraient changer était juste une prédiction. Personne n'avait observé directement ce type d'apprentissage dans le cervelet. Mais par le milieu des années 1980, des preuves s'étaient accumulées en faveur d'Albus. Il est devenu clair que la force de la connexion entre une cellule granulaire et une cellule de Purkinje diminue après une erreur. Les mécanismes moléculaires précis de ce processus ont même été révélés. Nous savons maintenant que les entrées des cellules granulaires causent un récepteur dans la membrane de la cellule de Purkinje à répondre, affectant ainsi d'identifier quelles entrées des cellules granulaires étaient actives à une certaine époque. Si une entrée par fibre de grimpe arrive plus tard (pendant un coup d'air), elle cause du calcium à inonder la cellule de Purkinje. La présence de ce calcium signale aux connexions étiquetées de diminuer leur force. Les patients atteints du syndrome de fragile X – une maladie génétique qui conduit aux incapacités intellectuelles – semblent manquer d'une protéine qui régule cette connexion des cellules granulaires vers la cellule de Purkinje. En conséquence, ils ont du mal à apprendre des tâches comme l'apprentissage conditionnel de l'ouverture de l'œil.

Le perceptron, avec ses règles explicites sur la façon dont l'apprentissage devrait se produire dans un réseau neuronal, a offert des idées testables claires pour que les neuroscientifiques puissent les rechercher et les trouver dans le cerveau. En faisant cela, il a été en mesure de relier la science entre

Échelles. Le plus petit détail physique – par exemple les ions de calcium se déplaçant à l'intérieur d'une neurone – hérite d'un sens beaucoup plus large en considérant son rôle dans la computation.

Le règne du perceptron a été abrégé en 1969. Et avec une ironie shakespearienne, c'est son nom qui l'a tué.

Perceptrons a été écrit par Marvin Minsky et Seymour Papert, tous deux mathématiciens à l'Institut de technologie du Massachusetts. Le livre était intitulé *_Introduction à la géométrie computationnelle_* et avait un simple design abstrait sur la couverture. Minsky et Papert ont été attirés pour écrire sur le sujet des perceptrons en raison de leur admiration pour l'invention de Rosenblatt et de leur désir d'en explorer davantage. En fait, Minsky et Papert se sont rencontrés à une conférence où ils présentaient des résultats similaires issus de leurs explorations sur la façon dont le perceptron apprend.

Papert était originaire d'Afrique du Sud avec des joues pleines, une barbe en bonne santé et pas un, mais *_deux_*, doctorats en mathématiques. Il avait une passion de longue date pour l'éducation et pour la façon dont elle pouvait être transformée par le calcul. Minsky était moins d'un an plus jeune que Papert, avec des traits plus fins et des lunettes larges. Un natif de New York, il a fréquenté le Lycée scientifique du Bronx avec Frank Rosenblatt ; il a également été mentoré par McCulloch et Pitts.

Minsky et Papert partageaient avec McCulloch et Pitts le désir compulsif de formaliser la pensée. Selon eux, des véritables progrès dans la compréhension de la computation provenaient de dérivations mathématiques. Toute l'efficacité empirique du perceptron – quels que soient les calculs qu'il était capable d'exécuter ou les catégories qu'il pouvait apprendre – n'avait d'importance que si on comprenait mathématiquement pourquoi et comment il fonctionnait.

À cette époque, le perceptron attirait beaucoup d'attention – et de fonds – de la communauté de l'intelligence artificielle. Mais il ne captivait pas le genre de scrutin mathématique que Minsky et Papert convoitaient. Les deux étaient donc explicitement motivés à écrire leur livre par un désir d'accroître la rigueur autour de l'étude des perceptrons – mais aussi, comme l'a reconnu plus tard Papert, par une certaine envie de réduire le respect envers eux.

Les pages du *_Perceptrons_* sont principalement composées de preuves, théorèmes et dérivations. Chacune contribue à l'histoire du perceptron : ce qu'il est, ce qu'il peut faire et comment il apprend. Cependant, à partir de la publication de ces quelque 200 pages – une exploration approfondie des mécanismes internes du perceptron – le message reçu par la communauté était principalement sur ses limites. C'est parce que Minsky et Papert avaient montré, de manière concluante, qu'il était impossible pour le perceptron d'exécuter certaines simples opérations.

Considérons un perceptron qui n'a que deux entrées, et chaque entrée peut être 'allumé' ou 'éteint'. Nous voulons que le perceptron rapporte si les deux entrées sont les mêmes : répondre oui (*_c'est-à-dire_* , avoir sa unité de lecture allumée) si les deux entrées sont allumées *_ou_* si les deux entrées sont éteintes. Mais si l'une est allumée et l'autre est éteinte, l'unité de lecture devrait être éteinte. Comme trier des chaussettes dans la lessive, le perceptron ne devrait répondre que lorsque il voit un couple correspondant.

Pour s'assurer que l'unité de lecture ne se déclenche pas seulement lorsque seule une entrée est allumée, les poids provenant de chaque entrée doivent être suffisamment bas. Ils pourraient par exemple chacun être la moitié de la quantité nécessaire pour faire tourner l'unité de lecture sur. De cette façon, lorsque les deux sont allumés, l'unité de lecture *_se déclenchera_* et elle ne se déclencherait pas si seulement une entrée est allumée. Dans ce setup, la lecture répond correctement pour trois des quatre conditions d'entrées possibles. Mais dans la condition où les deux entrées sont éteintes, l'unité de lecture sera éteinte – une classification incorrecte.

Il s'avère que peu importe combien nous ajustons les forces de connexion, il n'y a pas moyen de satisfaire toutes les exigences de la classification à la fois. Le perceptron ne peut tout simplement pas le faire. Et le problème est que aucun bon modèle du cerveau – ou intelligence artificielle prometteuse – ne devrait échouer à une tâche aussi simple que décider si deux choses sont les mêmes ou non.

Albus, dont le papier sur le cervelet a été publié en 1971, connaissait les limites du perceptron et savait qu'elles étaient encore importantes pour être un modèle de la tâche de conditionnement de l'éveil des yeux. Mais un modèle du cerveau humain entier, comme le promettait Rosenblatt ? Pas possible.

Le portrait que Minsky et Papert ont peint a forcé les chercheurs à voir clairement les pouvoirs du perceptron. Avant le livre, les chercheurs étaient capables d'explorer ce que le perceptron pouvait faire aveuglément, avec l'espoir que les limites de ses capacités étaient encore loin, si elles existaient du tout. Une fois que les contours furent mis en relief, cependant, il n'y avait plus à nier qu'il existait des frontières et qu'elles existaient beaucoup plus proches que prévu. En vérité, cela ne représentait rien d'autre que l'entendement du perceptron – exactement ce que Minsky et Papert s'étaient mis en tête de faire. Mais la fin de l'ignorance autour du perceptron signifiait également la fin de l'excitation à son sujet. Comme le disait Papert : « L'être compris peut être un sort aussi mauvais que la mort ».

La période qui suivit la publication de *Perceptrons* est connue sous le nom des « âges sombres » de la connexionnisme. Elle fut marquée par d'importantes diminutions du financement pour les programmes de recherche issus du travail initial de Rosenblatt. L'approche basée sur les réseaux neuronaux pour construire l'intelligence artificielle a été éteinte. Toutes les promesses excessives, espoirs et surenchères ont dû être retirées. Rosenblatt lui-même est décédé tragiquement dans un accident de bateau deux ans après la publication du livre et le domaine qu'il a aidé à construire resta inactif pendant plus de 10 ans.

Mais si l'hype autour du perceptron était excessif et mal informé, la contre-attaque qui s'en est suivie l'a été tout autant. Les limites mentionnées dans le livre de Minsky et Papert étaient vraies : le perceptron sous sa forme étudiée par eux était incapable de bien des choses. Mais il n'avait pas besoin de conserver cette forme. Le problème du même ou différent, par exemple, pouvait être facilement résolu en ajoutant une couche supplémentaire de neurones entre l'entrée et la sortie. Cette couche pourrait se composer de deux neurones, l'un avec des poids qui le font fonctionner lorsque les deux entrées sont activées et l'autre avec des poids qui le font fonctionner lorsque les deux entrées sont désactivées. Maintenant, le neurone de sortie, qui reçoit son entrée de ces neurones intermédiaires, n'a besoin que d'être actif si l'un des neurones intermédiaires est actif.

Les « multi-couches perceptrons », comme ces nouvelles architectures neuronales étaient appelées, avaient le potentiel de faire revivre la connexionnisme des morts. Mais avant une résurrection complète était possible, un problème devait être résolu : l'apprentissage. L'algorithme original du perceptron fournissait la recette pour définir les connexions entre les neurones d'entrée et les neurones de sortie – c'est-à-dire que la règle d'apprentissage était conçue pour un réseau à deux couches. Si le nouveau type de réseaux neuronales allait avoir trois, quatre, cinq ou plus de couches, comment devaient être définies les connexions entre toutes ces couches ? (voir la figure 6) Malgré tous les bons traits de la règle d'apprentissage du perceptron – sa simplicité, la preuve qu'elle pouvait fonctionner, le fait qu'elle ait été repérée dans le cervelet – elle était incapable de répondre à cette question. Savoir que un multi-couches perceptron *pouvait* résoudre des problèmes plus complexes n'était pas suffisant pour livrer sur les promesses grandioses du connexionnisme. Ce qui était nécessaire, c'est qu'il *apprenne* à résoudre ces problèmes.

La règle d'apprentissage originale du perceptron fonctionne parce que, avec seulement deux couches, il est facile de voir comment réparer ce qui ne va pas. Si un neurone de sortie est éteint quand il devrait être allumé, les connexions allant de la couche d'entrée à ce neurone doivent s'affaiblir et vice versa. La relation entre ces connexions et le neurone de sortie est ainsi claire. L'algorithme de backpropagation a un problème plus difficile à résoudre. Dans un réseau avec de nombreuses couches entre l'entrée et la sortie, les relations entre toutes ces connexions et la sortie ne sont pas aussi claires. Maintenant, au lieu d'un président et de ses conseillers, nous avons un président, ses conseillers et les employés de ceux-ci. La confiance qu'a un conseiller en n'importe quel employé – *c'est-à-dire* –, la force de la connexion de cet employé à ce conseiller – aura certainement un impact, finalement, sur ce que fait le président. Mais cet impact est plus difficile à voir directement et plus difficile à réparer si le président ressent qu'il y a quelque chose qui ne va pas.

Quelque chose était nécessaire pour calculer de manière explicite comment une connexion dans le réseau aurait un impact sur la couche de lecture. Il s'avère que les mathématiques offrent une méthode agréable pour faire cela. Considérons un réseau neuronal artificiel avec trois couches : d'entrée, intermédiaire et de lecture. Comment les connexions entre l'entrée et la couche intermédiaire affectent-elles la lecture ? Nous savons que l'activité de la couche intermédiaire est le résultat des activités des neurones d'entrée et des poids de leurs connexions vers la couche intermédiaire. Avec cette connaissance, écrire une équation pour savoir comment ces poids affectent l'activité dans la couche intermédiaire est tout à fait simple. Nous savons également que les neurones de lecture suivent la même règle : leur activité est déterminée par les activités des neurones intermédiaires et les poids reliant les neurones intermédiaires aux neurones de lecture. Par conséquent, une équation décrit comment ces poids affectent la lecture est également facile à obtenir. La seule chose qui reste à faire est de trouver un moyen de relier ces deux équations ensemble. De cette façon, nous aurons une équation qui nous dit directement comment les connexions entre l'entrée et la couche intermédiaire affectent la lecture.

Lors de la formation d'un train dans le jeu des dominoes, le nombre en fin d'une tuile doit correspondre au nombre en début d'une autre pour qu'elles puissent se connecter. La même chose est vraie pour les équations qui suivent l'une après l'autre ici. Le terme commun qui relie ces deux équations est l'activité de la couche intermédiaire : cette activité détermine à la fois l'activité de la sortie et est elle-même déterminée par les connexions entre l'entrée et la couche intermédiaire. Après avoir joint ces équations via l'activité de la couche intermédiaire, l'impact des connexions entre l'entrée et la couche intermédiaire sur la sortie peut être calculé directement. Et cela rend facile de déterminer comment modifier ces connexions lorsque la sortie est incorrecte. Dans le calcul, ce lien entre les relations se nomme "la règle des chaînes" et il constitue le noyau de l'algorithme de backpropagation.

La règle de la chaîne a été découverte il y a plus de 200 ans par l'idole de McCulloch et Pitts, le philosophe et polymathe Gottfried Leibniz. Étant donné son utilité, son application à l'entraînement de réseaux neuronaux multi-couches n'était pas une surprise. En fait, l'algorithme de backpropagation semble avoir été inventé au moins trois fois avant 1986. Mais le papier de 1986 faisait partie d'une tempête parfaite qui a assuré que ses conclusions se répandraient loin et large. La première raison de ce succès était le contenu du papier lui-même. Non seulement montrait-il qu'il était possible d'entraîner des réseaux neuronaux de cette manière, mais il analysait également les mécanismes de réseaux entraînés sur plusieurs tâches cognitives, telles que la compréhension des relations dans une famille. Un autre facteur clé du succès était l'augmentation de la puissance de calcul qui est venue dans les années 1980 ; cela a été important pour rendre l'entraînement des réseaux neuronaux multi-couches pratiquement possible pour les chercheurs. Enfin, la même année où le papier a été publié, l'un de ses auteurs, Rumelhart, a également publié un livre sur la connexionnisme qui comprenait l'algorithme de backpropagation. Ce livre – écrit avec un autre professeur de Carnegie Mellon, James McClelland – a vendu environ 40 000 exemplaires d'ici les années 1990. Son titre, *Traitement parallèle et distribué*, a prêté son nom à l'entière agenda de recherche consistant à construire des réseaux neuronaux artificiels dans la fin des années 1980 et le début des années 1990.

Pour des raisons similaires, l'histoire des réseaux de neurones artificiels a pris un tournant encore plus dramatique environ une décennie après le début du nouveau millénaire. Les quantités massives de données accumulées dans l'ère d'internet se sont unies à la puissance de calcul du XXI^e siècle pour accélérer les progrès dans ce domaine. Des réseaux avec de plus en plus de couches pouvaient soudainement être entraînés sur des tâches de plus en plus complexes. De tels modèles échelonnés – dénommés « réseaux neuronaux profonds » – sont actuellement en train de transformer l'intelligence artificielle et la neurosciences à parts égales.

Les réseaux neuronaux profonds d'aujourd'hui se fondent sur la même compréhension de base des neurones que celle de McCulloch et Pitts. Au-delà de cette inspiration de base, ils ne visent pas à reproduire directement le cerveau humain. Ils n'essaient pas de simuler sa structure ou son anatomie, par exemple¹¹.

Mais ils visent à simuler le comportement humain et ils y sont très bons. Lorsque le service de traduction de langues populaire de Google a commencé à utiliser une approche de réseau neuronal profond en 2016, il a réduit les erreurs de traduction de 50 %. YouTube utilise également des réseaux neuronaux pour aider son algorithme de recommandation à mieux comprendre ce que les gens veulent voir. Et lorsque l'assistant vocal Siri d'Apple répond à une commande, c'est un réseau neuronal profond qui écoute et parle.

Au total, les réseaux neuronaux profonds peuvent maintenant être entraînés pour trouver des objets dans des images, jouer à des jeux, comprendre les préférences, traduire entre différentes langues, convertir la parole en mots écrits et convertir les mots écrits en parole. Pas très différent de l'ordinateur Perceptron original, les ordinateurs sur lesquels ces réseaux fonctionnent remplissent des salles. Ils sont situés dans des centres de serveurs à travers le monde, où ils bourdonnent et traitent les données d'image, de texte et audio du monde. Rosenblatt aurait peut-être été heureux de constater que certaines de ses promesses grandioses au *New York Times* étaient effectivement réalisées. Elles n'avaient simplement pas besoin d'une échelle presque mille fois supérieure à celle dont il disposait à l'époque.

L'algorithme de backpropagation était nécessaire pour pousser les réseaux de neurones artificiels à un point où ils pouvaient atteindre des niveaux de performance proches de ceux d'un humain sur certaines tâches. Comme règle d'apprentissage pour les réseaux de neurones, il fonctionne vraiment. Malheureusement, cela ne signifie pas qu'il fonctionne comme le cerveau. Alors que la règle d'apprentissage du perceptron était quelque chose qui pouvait être vu en jeu entre des neurones réels, l'algorithme de backpropagation ne l'est pas. Il a été conçu comme un outil mathématique pour faire fonctionner les réseaux de neurones artificiels, et non comme un modèle du mode d'apprentissage du cerveau (et ses inventeurs étaient très clairs là-dessus dès le début). La raison en est que les neurones réels peuvent généralement ne pas connaître l'activité des neurones auxquels ils sont connectés – et pas non plus celle des neurones qui se connectent à ceux-ci, et ainsi de suite. Pour cette raison, il n'y a pas d'évidence évidente pour que les neurones réels puissent mettre en œuvre la règle du chien. Ils doivent donc faire quelque chose d'autre.

Pour certains chercheurs – notamment les chercheurs dans le domaine de l'intelligence artificielle – la nature artificielle de la backpropagation n'est pas un problème. Leur objectif est de construire des ordinateurs qui peuvent penser, par tous les moyens nécessaires. Mais pour d'autres scientifiques – en particulier les neuroscientifiques – trouver l'algorithme d'apprentissage du cerveau est primordial. Nous savons que le cerveau est bon dans la poursuite de l'amélioration ; nous le voyons quand on apprend un instrument musical, comment conduire ou lire une nouvelle langue. La question est : comment ?

Parce que la rétro-propagation est ce qui fonctionne bien, certains neuroscientifiques commencent par là. Ils vérifient des signes pour savoir si le cerveau fait quelque chose comme la rétro-propagation, même s'il ne peut pas le faire exactement. L'inspiration vient du succès de la découverte d'un perceptron au travail dans le cervelet. Là-bas, les indices étaient présents dans l'anatomie ; la différente disposition des fibres de montée et des cellules granulaires indiquait un rôle différent pour chacune. D'autres régions du cerveau présentent des modèles de connectivité qui peuvent suggérer comment elles apprennent. Par exemple, dans le néocortex, certaines neurones ont des dendrites qui s'étendent bien au-dessus d'eux. Des régions lointaines du cerveau envoient des entrées à ces dendrites. Elles transportent-elles avec elles de l'information sur la manière dont ces neurones ont impacté ceux qui viennent après eux dans le réseau neuronal du cerveau ? Cette information pourrait-elle être utilisée pour modifier la force des connexions du réseau ? Les neuroscientifiques et les chercheurs en intelligence artificielle gardent espoir que la version du cerveau de la rétro-propagation sera trouvée et qu'elle peut être copiée pour créer des algorithmes qui apprennent mieux et plus vite que les réseaux neuronaux artificiels d'aujourd'hui.

Les chercheurs modernes qui cherchent à comprendre comment l'esprit apprend de la supervision font exactement ce que McCulloch a fait. Ils regardent les montagnes de faits que nous avons sur la biologie du cerveau et essaient de voir dans cela une structure computationnelle. Aujourd'hui, ils sont guidés dans leur recherche par le fonctionnement des systèmes artificiels. Demain, les découvertes en biologie guideront à nouveau la construction d'intelligence artificielle. Cette oscillation définit la relation symbiotique entre ces deux domaines. Les chercheurs qui cherchent à construire des réseaux neuronaux artificiels peuvent trouver inspiration dans les modèles trouvés dans ceux biologiques, tandis que les neuroscientifiques peuvent se tourner vers l'étude de l'intelligence artificielle pour identifier le rôle computationnel des détails biologiques. De cette manière, les réseaux neuronaux artificiels maintiennent la connexion entre l'étude de l'esprit et du cerveau.

****Notes****

- > 1 Nommé d'après le mathématicien anglais George Boole. Même s'ils ont utilisé ses idées, Russell et Whitehead n'ont pas utilisé en réalité le terme « Boolean », car il n'a été inventé qu'en 1913.
- > 2 C'est ce que cela semblait à l'époque ... Plus sur cela plus tard.
- > 3 L'utilisation du mot « circuit » ici diffère de celle dans le dernier chapitre. En plus de son sens comme un circuit électrique, les neuroscientifiques utilisent également le mot pour faire référence à un groupe de neurones connectés d'une manière spécifique.
- 4 Plus sur la façon dont l'apprentissage – et la mémoire – dépendent d'un changement dans les connexions dans le prochain chapitre.

- 5 Cela peut être considéré comme représentant le *_taux_* de spiking d'un neurone, plutôt que si le neurone émet une impulsion ou non. En utilisant ce type de neurone artificiel nécessite seulement une petite modification à la procédure d'apprentissage.
- 6 Les fissures dans les fondations du *_Principia_* étaient déjà visibles lorsqu'il a été publié. Certaines des « prémisses de base » qu'il devait supposer n'étaient pas vraiment très basiques et étaient difficiles à justifier.
- 7 Cette réalisation est venue encore plus directement d'une étude sur le cerveau de grenouille dont Pitts était impliqué. Plus d'informations sur cette étude dans le Chapitre 6 .
- 8 La cartographie est parfois appelée la « théorie Marr-Albus-Ito » du apprentissage moteur, nommée également après David Marr et Masao Ito, qui ont tous deux présenté des modèles similaires sur la façon dont le cervelet apprend.
- 9 Les mots utilisés par Papert pour décrire ses sentiments à l'époque sur la « Perceptron-mania » étaient « hostilité » et « gêne ».
- 10 Techniquement, ils n'étaient pas vraiment « nouveaux ». Minsky et Papert font référence aux perceptrons multi-couches dans leur livre. Cependant, ils ont été dédaigneux quant à la puissance potentielle de ces dispositifs et, malheureusement pour la science, ne les ont pas encouragés davantage.
- 11 Avec l'exception des réseaux neuronaux profonds conçus pour comprendre les images, dont nous entendrons parler dans le Chapitre 6 .

CHAPITRE QUATRE

Liens du document original

- <<http://www.jstor.org/stable/4028156>>
- <<http://ai.googleblog.com/2016/09/a-neural-network-for-machine.html>>
- <<http://annurev.ph/>>
-
- <<http://nautil.us/issue/21/information/the-man-who-tried-to-redeem-the-world-with-logic>>
- <<https://plato.stanford.edu/archives/fall2019/entries/principia-mathematica/>>
- <<http://www.jstor.org/stable/20025136>>
- <<http://people.idsia.ch/~juergen/who-invented-backpropagation.html>>
- <<https://pni.princeton.edu/john-hopfield/john-j.-hopfield-now-what>>
- <<http://www.jneurosci.org/content/16/6/2112>>
-
- <<http://papers.nips.cc/paper/890-a-model-of-the-neural-basis-of-the-rats-sense-of-direction.pdf>>

-
- <<https://www.scientificamerican.com/article/do-brain-waves-conduct-neural-activity-like-a-symphony>>
- <<https://www.sciencedaily.com/releases/2019/07/190718112415.htm>>
- <<https://www.jstor.org/stable/4320507>>
- <<http://arxiv.org/abs/1502.01852>>
- <<http://www.ncbi.nlm.nih.gov/pmc/articles/PMC1359523/>>
- <<https://doi.org/10.1109/34.291440>>
-
- <<https://mitpress.universitypressscholarship.com/view/10.7551/mitpress/9780262083775.001.0001/upso-9780262083775-chapter-17>>
- <<https://ieeetv.ieee.org/video/interview-with-fukushima-2015>>
- <<https://doi.org/10.1145/3065386>>
- <<https://dspace.mit.edu/handle/1721.1/6125>>
-
- <<https://blogs.scientificamerican.com/cross-check/profile-of-claude-shannon-inventor-of-information-theory>>
-
- <<https://mitpress.universitypressscholarship.com/view/10.7551/mitpress/9780262083775.001.0001/upso-9780262083775-chapter-18>>
- <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC1368193>>
- <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5281805>>
-
- <<http://www.theatlantic.com/health/archive/2012/06/the-neural-rhythms-that-move-your-body/258094>>
- <<http://archive.org/details/functionsofbrain1876ferr>>
- <<http://www.wired.co.uk/article/braingate>>
-
- <<http://www.sciencemag.org/news/2019/04/physicist-trying-make-sense-brain-s-tangled-networks>>
- <<https://ui.adsabs.harvard.edu/abs/1972NASSP.281..187C/abstract>>
- <<http://www.rand.org/pubs/papers/P550.html>>
-
- <<http://www.vox.com/2016/7/19/12231776/google-energy-deepmind-ai-data-centers>>
- <<http://arxiv.org/abs/1312.5602>>
- <<http://www.newyorker.com/magazine/2014/11/24/drool>>
- <http://www.theregister.co.uk/2014/03/29/hawkins_ai_feature>
- <<https://lexfridman.com/jeff-hawkins>>
- <<http://arxiv.org/abs/1906.10184>>
-
- <<http://www.nytimes.com/2018/10/14/technology/jeff-hawkins-brain-research.html>>
-
- <<https://www.wired.com/story/karl-friston-free-energy-principle-artificial-intelligence/>>
-
- <<http://www.technologyreview.com/2015/04/08/11480/ibm-tests-mobile-computing-pioneers-controversial-brain-algorithms>>
- <<http://www.bloomsbury.com/>>

La création et la maintenance des souvenirs

Le réseau de Hopfield et les attracteurs

Un bloc d'acier à 770°C (1 418°F) est un maillage robuste gris. Chaque l'un de ses trillions d'atomes sert comme une brique unique dans les murs parallèles infinis et les plafonds de sa structure cristalline. C'est un modèle de régularité. En opposition à leur arrangement structurale organisé, cependant, la disposition magnétique de ces atomes est un désordre.

Chaque atome d'acier forme un dipôle – un aimant miniature avec une extrémité positive et une négative. La chaleur trouble ces atomes, faisant basculer la direction de leurs pôles au hasard. Au niveau microscopique, cela signifie que beaucoup de petits aimants exercent chacun une force dans sa propre direction. Mais comme ces forces s'exercent les unes contre les autres, leur effet global devient négligeable. Lorsque vous zoompez sur cette masse d'aimants miniatures, elle n'a aucune magnétisme du tout.

Lorsque la température chute en dessous de 770°C, cependant, quelque chose change. La direction individuelle d'un atome est moins susceptible de basculer. Avec son dipôle fixé, l'atome commence à exercer une pression constante sur ses voisins. Cela leur indique quelle direction ils devraient prendre. Les atomes avec des directions différentes s'affrontent pour influencer le groupe local jusqu'à ce que finalement tout le monde se mette d'accord, d'une manière ou d'une autre. Avec tous les petits dipôles alignés, la force nette est forte. Le bloc d'acier inerte devient un aimant puissant.

Philip Warren Anderson, un physicien américain qui a remporté un prix Nobel en travaillant sur de telles phénomènes, a écrit dans un essai maintenant célèbre intitulé « More is different » que « le comportement de grands et complexes agrégats de particules élémentaires, il s'avère, ne peut pas être compris en termes d'une simple extrapolation des propriétés de quelques particules ». C'est-à-dire que

l'action collective de nombreux petits particules – organisées uniquement par leurs interactions locales – peut produire une fonction qui n'est pas directement possible dans aucune d'elles seules. Les physiciens ont formalisé ces interactions en équations et y ont réussi à expliquer le comportement des métaux, des gaz et de la glace.

Dans les années 1970, un collègue d'Anderson, John J. Hopfield, a vu dans ces modèles mathématiques du magnétisme une structure semblable à celle du cerveau. Hopfield a utilisé cette intuition pour mettre sous contrôle mathématique une mystérieuse question qui perdurait : la question de savoir comment les neurones créent et maintiennent des souvenirs.

Richard Semon était dans l'erreur.

Un biologiste allemand travaillant à la fin du xxe siècle, Sémon a écrit deux livres volumineux sur la science de la mémoire. Ils étaient remplis de descriptions détaillées des résultats expérimentaux, des théories et d'un vocabulaire pour décrire l'impact de la mémoire sur le « tissu organique ». Le travail de Sémon était éclairé, honnête et clair – mais il contenait une grave erreur. Comme le naturaliste français Jean-Baptiste Lamarck croyait (en contraste avec notre compréhension actuelle de l'évolution) que les traits acquis par un animal au cours de sa vie pouvaient être transmis à ses descendants, Sémon proposa que les *mémoires* acquises par un animal pourraient être transmises. C'est-à-dire qu'il croyait que les réponses apprises d'un organisme à son environnement propre donneraient lieu sans instruction dans ses descendants. En raison de cette intuition erronée, une grande partie du travail précieux de Sémon a été lentement mise de côté et oublié.

Être en faute sur la mémoire n'est pas inhabituel. Le philosophe René Descartes, par exemple, pensait que les souvenirs étaient activés par une petite glande dirigeant le flux des « esprits animaux ». Ce qui est unique chez Sémon est qu'en dépit de l'erreur dans son travail qui l'a condamné à l'obscurité historique, l'une de ses contributions a demeuré influente longtemps assez pour engendrer un corps entier de recherche. Cette petite œuvre de ses efforts est l'« engramme » – un mot créé par Sémon dans *The Mneme* en 1904, et appris depuis par des millions d'étudiants de psychologie et de neurosciences.

À l'époque où Semon écrivait, la mémoire n'avait que récemment été soumise à une étude scientifique – et la plupart des résultats concernaient uniquement les capacités de mémorisation, pas la biologie. Par exemple, les gens seraient entraînés pour retenir des paires de mots absurdes (comme « wsp » et « niq ») et ils étaient ensuite testés sur leur capacité à récupérer le deuxième mot lorsque le premier était présenté.

Ce type de mémoire, connu sous le nom de *mémoire associative*, deviendrait un objectif de recherche pendant des décennies à venir. Mais Semon était intéressé par plus que juste le comportement ; il voulait savoir quelles modifications dans la physiologie d'un animal pourraient soutenir ces souvenirs associatifs.

Dirigé par des données expérimentales rares, il a décomposé le processus de création et de récupération de souvenirs en plusieurs composants. En trouvant les mots communs trop vagues et surchargés, il a créé des termes novateurs pour ces divisions du travail. Le mot qui serait devenu si influent, l'engramme, était défini comme « la modification durable, principalement latente, dans la substance irritable produite par un stimulus ». Ou, pour le dire plus clairement : les changements physiques dans le cerveau qui se produisent lorsque se forme une mémoire. Un autre terme, « échophorie », était attribué aux « influences qui réveillent la trace mnésique ou l'engramme de son état latent à un d'une activité manifestée ». Cette distinction entre engramme et échophorie (ou entre les processus qui créent une mémoire et ceux qui la récupèrent) était l'un des nombreux progrès conceptuels que le travail de Semon a fournis. Malgré le fait que son nom et la plupart de sa langue ont disparu de la littérature, beaucoup de ses intuitions conceptuelles étaient correctes et elles forment le cœur de la façon dont les souvenirs sont modélisés aujourd'hui.

En 1950, le psychologue américain Karl Lashley a publié « À la recherche de l'engramme », un article qui a solidifié la légende du mot. Il a également fixé une tonalité plutôt sombre pour le domaine. Le titre était ainsi choisi parce que la recherche était tout ce que Lashley avait accompli en 30 ans d'expériences. Les expériences de Lashley impliquaient la formation d'animaux à faire une association (par exemple, réagir d'une certaine manière lorsqu'ils étaient montrés un cercle plutôt qu'un 'X') ou apprendre une tâche, comme savoir se déplacer dans un labyrinthe particulier. Il supprimait ensuite des zones cérébrales spécifiques ou les voies de connexion et observait comment la conduite était impactée post-opérativement. Lashley n'a pas pu trouver aucune zone ou modèle de lésions qui interférerait de manière fiable avec la mémoire. Il a conclu que les souvenirs doivent donc être distribués également à travers le cerveau, plutôt qu'en une seule zone. Mais en fonction de certains calculs sur le nombre de neurones pouvant être utilisés pour un souvenir et le nombre de voies entre eux, il était incertain sur la façon dont cela était possible. Son article emblématique est donc quelque chose comme un drapeau blanc, une capitulation de toute tentative de conclure sur l'emplacement de la mémoire face à une masse de

L'approche de Hebb, qui se concentre sur la synapse, situe l'engramme à la fois local et global : local car l'impression d'une mémoire se produit au petit espace où deux neurones se rencontrent, mais global car ces changements peuvent se produire aux synapses partout dans le cerveau. Cela fait également de la mémoire la conséquence naturelle de l'expérience : avec des synapses pliables, toute activation du cerveau a le potentiel de laisser une trace.

Lashley, un scientifique dévoué résolu à suivre les faits, accepta que l'engramme doit être distribué sur la base de ses propres expériences. Mais il ne trouva pas satisfaction dans la solution de Hebb, qui – bien qu'une théorie séduisante et élégante – était basée plus sur des spéculations que sur des preuves solides. Il refusa l'offre de Hebb pour être co-auteur du travail.

Lashley peut ne pas avoir soutenu les idées de Hebb, mais depuis la publication de son livre, des dizaines d'expériences ont prouvé le contraire. Les limaces de mer – des mollusques bruns et glissants de longueur de pied avec environ 20 000 neurones – sont devenus un objet d'étude dans ce domaine en raison de leur capacité à apprendre une association très basique. Ces mollusques sans coquille ont une branchie sur leur dos qui, si menacés, peut être rapidement rétracté pour se mettre en sécurité. Dans le laboratoire, une brève décharge électrique fera retirer la branchie. Si une telle décharge est précédée plusieurs fois par un toucher inoffensif de lumière, les limaces commenceront finalement à retirer la branchie en réponse au seul toucher, démontrant ainsi une association entre le toucher et ce qui peut suivre. C'est l'équivalent marin d'apprendre à associer « *wsp* » avec « *niq* ». Cette association a été montrée, conformément à la théorie de Hebb sur l'apprentissage, être médiane par un renforcement des connexions entre les neurones qui représentent le toucher et ceux qui mènent à la réponse de la branchie. Le changement du comportement est forgé par une modification des connexions.

L'apprentissage hebbien n'a pas seulement été observé ; il a également été contrôlé. En 1999, des chercheurs de Princeton ont montré que modifier génétiquement les protéines dans la membrane cellulaire qui contribuent aux changements synaptiques peut contrôler la capacité d'apprentissage d'une souris. Augmenter la fonction de ces récepteurs améliore l'aptitude des souris à se souvenir d'objets qu'elles ont déjà vus. L'interférence avec ces protéines les empêche.

Il est maintenant établi scientifiquement que l'expérience conduit à l'activation de neurones et qu'une activation de neurones peut modifier les connexions entre eux. Cette histoire est acceptée comme au moins une partie de la réponse à la question de l'engramme.

Mais, comme le décrit Semon, l'engramme lui-même n'est que partie intégrante de l'*histoire* complète de la mémoire. La mémoire nécessite également la *mémorisation*. Comment cette façon de déposer des souvenirs peut-elle permettre un stockage à long terme et une récupération ?

Ce n'était pas vraiment une surprise que John J. Hopfield devienne physicien. Né en 1933 de John Hopfield Sr, un homme qui s'est fait connaître dans la spectroscopie ultraviolette, et d'Helen Hopfield, qui a étudié les radiations électromagnétiques atmosphériques, Hopfield Jr a grandi dans une maison où la physique était autant une philosophie qu'une science. « La physique est un point de vue selon lequel le monde autour de nous est, avec effort, ingéniosité et ressources suffisantes, compréhensible d'une manière prédictive et relativement quantitative », a écrit Hopfield dans une autobiographie. « Être physicien est une dévotion à la quête de ce genre de compréhension ». Et c'est ainsi qu'il serait physicien.

Hopfield, un homme grand et maigre avec un sourire engageant, a obtenu son doctorat en 1958 à l'Université de Cornell. Il a poursuivi ses études en recevant une bourse Guggenheim, qu'il a utilisé pour étudier au Laboratoire Cavendish à Cambridge. Mais même à cette époque, l'intérêt de Hopfield pour le sujet de sa thèse – la physique des matériaux condensés – commençait à faiblir. « En 1968, j'avais épuisé les problèmes ... auxquels mes talents particuliers semblaient utiles », a-t-il écrit plus tard.

La passerelle de Hopfield entre la physique et la biologie était l'hémoglobine, une molécule qui sert une fonction biologique cruciale en transportant l'oxygène dans le sang et pouvait être étudiée avec de nombreuses techniques de physique expérimentale à l'époque. Hopfield a travaillé sur la structure de l'hémoglobine pendant plusieurs années au Bell Labs, mais il a trouvé son véritable appel en biologie après avoir été invité à une série de conférences sur la neurosciences à Boston dans les années 1970. C'est là qu'il a rencontré un groupe varié de cliniciens et de neuroscientifiques réunis pour aborder la question profonde de savoir comment l'esprit émerge du cerveau. Hopfield était captivé.

Même s'il avait une pensée mathématique, Hopfield était déçu par l'approche qualitative du cerveau qu'il a vue en spectacle. Il était préoccupé par le fait que, malgré leurs talents évidents en biologie, ces chercheurs « n'étaient jamais capables de résoudre le problème car la solution peut être exprimée seulement

<!-- Début du texte de l'image -->

Réseau Hopfield
0.
' nous
i ~,
~~
1 a. sommes y
\ = ce Pa
f
1 o F f
1 _ " 4 r v i
- F AN é f
- 7 \ f l ' é f
i i 4 %
f
i
'
* . \ ' A ; sur
moi i 1.4. P ' a l f i
* 5 f f *
* . 1 r ,
moi off
% Ca wo
an =
--- connexion
<!-- Fin du texte de l'image -->

entre ces neurones d'où émergent les comportements intrigants de ce réseau.

Le réseau Hopfield est récurrent , signifiant que chaque activité neuronale est déterminée par celle des autres dans le réseau. Par conséquent, chaque activité neuronale sert à la fois d'entrée et de sortie pour ses voisins. Spécifiquement, chaque entrée reçue par un neurone d'un autre neurone est multipliée par un nombre particulier – un poids synaptique. Ces entrées pondérées sont ensuite additionnées et comparées à un seuil : si la somme est supérieure (ou égale) au seuil, l'activité neuronale a une valeur 1 ('allumé'), sinon elle vaut 0 ('éteint'). Cette sortie se nourrit ensuite des calculs d'entrée des autres neurones dans le réseau, dont les sorties se nourrissent à leur tour de plus de calculs d'entrée et ainsi de suite.

Comme des corps dans un pit de mosh, les composants d'un système récurrent poussent et tirent l'un sur l'autre, avec l'état d'une unité à n'importe quel moment donné déterminé par ceux qui l'entourent. Les neurones dans un réseau de Hopfield sont ainsi semblables aux atomes d'acier qui s'influencent constamment les uns les autres grâce à leurs interactions magnétiques. Les effets de cette interaction incessante peuvent être nombreux et complexes. Prédire les modèles que ces parties interconnectées généreront est essentiellement impossible sans la précision d'un modèle mathématique. Hopfield connaissait intimement ces modèles et leur capacité à montrer comment les interactions locales conduisent à l'émergence du comportement global.

Hopfield a découvert que si les poids entre les neurones dans son réseau sont juste au bon niveau, le réseau peut mettre en œuvre la mémoire associative dans son ensemble. Pour comprendre cela, nous devons d'abord définir ce qui compte comme une mémoire dans ce modèle abstrait. Imaginez que chaque neurone dans un réseau de Hopfield représente une seule objet : le neurone A est un fauteuil berçant, le neurone B est une bicyclette, le neurone C est un éléphant, et ainsi de suite. Pour représenter une mémoire particulière, disons celle de votre chambre d'enfant, les neurones qui représentent tous les objets présents dans cette pièce – le lit, vos jouets, les photographies sur le mur – devraient être « allumés » ; tandis que ceux qui représentent des objets n'y étant pas présents – la lune, un autobus en ville, les couteaux de cuisine – devraient être « éteints ». Le réseau dans son ensemble est alors dans l'état d'activité « votre chambre d'enfant ». Un autre état d'activité différent – avec des ensembles différents de neurones « allumés » ou « éteints » – représenterait une mémoire différente.

Dans la mémoire associative, un petit input sur le réseau réactive tout l'état de mémoire. Par exemple, voir une photo de vous-même dans votre chambre d'enfant

Le lit peut activer certains des neurones qui représentent votre chambre : les neurones du lit et les neurones de l'oreiller, et ainsi de suite. Dans le réseau Hopfield, les connexions entre ces neurones et ceux qui représentent d'autres parties de la chambre – les rideaux et vos jouets et votre bureau – font en sorte que ces autres neurones deviennent actifs, recréant l'expérience complète de la chambre. Les connexions négativement pondérées entre les neurones de la chambre et ceux qui représentent par exemple un parc local, assurent que la mémoire de la chambre ne soit pas infiltrée par d'autres objets. De cette façon, vous ne finissez pas par vous souvenir d'un jeu de balançoire à côté du placard.

Lorsque certains neurones s'allument et que d'autres s'éteignent, c'est leur interactivité qui met en relief la mémoire complète. C'est ainsi que le réseau effectue le lourd travail de la mémoire. Ce sont les synapses qui assurent cette tâche formidable et délicate de récupération de la mémoire.

Dans le langage de la physique, une mémoire complètement récupérée est un exemple d' *_attracteur_* . Un attracteur, en fin de compte, est un motif populaire d'activité. Il s'agit d'un motif dont les autres motifs d'activité évolueront vers lui, tout comme l'eau est attirée par une descente. Une mémoire est un attracteur car l'activation d'une poignée de neurones qui forment la mémoire fera en sorte que le réseau remplit le reste. Une fois qu'un réseau est dans un état attracteur, il y reste avec les neurones fixés dans leurs positions « allumées » ou « éteintes ». Toujours friands de décrire les choses en termes d'énergie, les physiciens considèrent les attracteurs comme des « états à faible énergie ». Ils sont une position confortable pour un système ; c'est ce qui les rend attirants et stables.

Imaginez un trampoline avec une personne debout dessus. Une balle placée n'importe où sur le trampoline roulera vers la personne et restera là. La balle étant dans les creux créés par la personne est ainsi un état attracteur pour ce système. Si deux personnes de même taille étaient debout l'une en face de l'autre sur le trampoline, le système aurait deux attracteurs. La balle roulerait vers qui elle était initialement la plus proche, mais toutes les routes mèneraient toujours à un attracteur.

Les systèmes de mémoire ne seraient d'aucune utilité si ils n'avaient qu'un seul mémoire, il est donc important que le réseau de Hopfield puisse soutenir plusieurs attracteurs. De la même manière que la balle est attirée vers le point bas le plus proche sur le trampoline, les états initiaux d'activité neuronale évoluent vers le mémoire le plus similaire (voir Figure 9). Les états initiaux qui mènent à un attracteur de mémoire spécifique – par exemple, l'image de votre lit d'enfance qui réactive la mémoire de toute la pièce ou une excursion à la plage qui déclenche la mémoire d'une vacances d'enfance – sont dits se trouver dans le « bassin d'attraction » de ce mémoire.

The Pleasures of Memory est un poème de 1792 de Samuel Rogers. Réfléchissant sur le voyage universel que la mémoire peut faire à l'esprit, il a écrit :

_Dans les innombrables chambres du cerveau, _

_Nos pensées sont liées par de nombreuses chaînes cachées. _

_Si vous réveillez une seule, voilà qu'un myriade d'autres se lèvent ! Chacune y imprime son image tandis que les autres s'enfuient ! _

La chaîne cachée de Rogers peut être trouvée dans le modèle de poids qui réactive une mémoire dans le réseau Hopfield. En effet, le modèle d'attracteur correspond à beaucoup de notre intuition sur la mémoire. Il aborde implicitement le temps qu'il faut pour restaurer les souvenirs, car le réseau a besoin du temps nécessaire pour activer les bons neurones. Les attracteurs peuvent également être légèrement déplacés dans le réseau, créant des souvenirs qui sont principalement corrects, avec un détail ou deux changé. Et les souvenirs trop similaires se fondent simplement en un seul.

La compression de la mémoire en une série de zéros et de uns peut sembler une offense à la richesse de notre expérience de la mémoire, mais c'est justement la condensation de ce processus qui semble ineffable qui met l'explication de celui-ci à portée de main.

Différents entrées réactivent différents souvenirs

0 0 o0
*)
entrée:. 7) o0
o0
Oo
000 0 we)
o0
souvenir: Oo
o0 o0
00
00 0 o0 o0

Les connexions et les autres se situent quelque part entre. C'est tout simplement la connectivité nécessaire pour former des attracteurs.

Les attracteurs ne sont pas des phénomènes triviaux. Après tout, si tous les neurones d'un réseau envoient et reçoivent constamment des entrées, pourquoi devrions-nous supposer que leur activité s'installerait jamais dans un état de mémoire, encore moins l'état de mémoire *adéquat* ? Pour être certain que les attracteurs adéquats se formeraient dans ces réseaux, Hopfield a dû faire une hypothèse plutôt étrange : les poids du réseau de Hopfield sont *symétriques*. Cela signifie que la force de la connexion entre le neurone A et le neurone B est toujours la même que celle de la connexion de B à A. En imposant cette règle, on obtenait une garantie mathématique d'attracteurs. Le problème est que les chances de trouver un peuplement de neurones comme celui-ci dans le cerveau sont très faibles, voire inexistantes. Il faudrait que chaque axone sortant d'une cellule et formant une synapse avec une autre soit exactement égal à cette même cellule envoyant son axone vers l'avant, se connectant au premier neurone avec la même force. La biologie n'est pas aussi propre.

Cela met en lumière l'éternelle tension entre l'approche mathématique de la biologie. La perspective du physicien, qui repose sur un degré presque irrationnel de simplification, est constamment à l'opposé de la biologie, pleine d'informations délicates et incommodes. Dans ce cas, les détails des maths exigeaient des poids symétriques pour faire une déclaration définitive sur les attracteurs et ainsi progresser dans la modélisation du processus de mémoire. Un biologiste aurait probablement rejeté l'hypothèse de manière catégorique.⁶

Hopfield, avec un pied sur chaque côté de la division mathématique-biologie, savait apprécier le point de vue des neuroscientifiques. Pour apaiser leurs inquiétudes, il a montré dans son article original que – même si cela ne pouvait pas être garanti mathématiquement – les réseaux qui permettaient des poids asymétriques semblaient encore capables d'apprendre et de maintenir des attracteurs relativement bien.

Le réseau Hopfield offrait ainsi une preuve de concept selon laquelle les idées de Hebb sur l'apprentissage pourraient fonctionner réellement. Au-delà de cela, il offrait une chance d'étudier mathématiquement la mémoire – de la quantifier. Par exemple, précisément combien de souvenirs peut un réseau conserver ? C'est une question qui ne peut être posée qu'avec un modèle précis de la mémoire en tête. Dans la version la plus simple du réseau Hopfield, le nombre de souvenirs dépend du nombre de neurones dans le réseau. Un réseau avec 1 000 neurones, par exemple, peut conserver environ 140 souvenirs ; 2 000 neurones peuvent conserver 280 ; 10 000 peuvent conserver 1 400 et ainsi de suite.

Si le nombre de souvenirs reste inférieur à environ 14 % du nombre de neurones, chaque souvenir sera restauré avec une erreur minimale. Cependant, en ajoutant plus de souvenirs, cela sera comme la dernière addition à une maison de cartes qui fait s'effondrer l'ensemble. Lorsqu'on le pousse au-delà de sa capacité, le réseau Hopfield s'effondre : les entrées se dirigent vers des attracteurs sans signification et aucun souvenir n'est récupéré avec succès. C'est un phénomène qui a reçu le nom dramatique approprié « catastrophe noire ».

La précision ne peut pas être évitée ; une fois que cette estimation de la capacité de mémoire est trouvée, il est raisonnable de commencer à se demander si elle correspond au nombre de souvenirs que nous savons être stockés par le cerveau. Une étude emblématique en 1973 a montré que les personnes qui avaient été présentées à plus de 10 000 images (chaque fois seulement une fois et pour une période très courte) étaient tout à fait capables de les reconnaître ultérieurement. Les 10 millions de neurones du cortex péri-sphérique – une région cérébrale impliquée dans la mémoire visuelle – pourraient stocker cette quantité d'images, mais cela ne laisserait pas beaucoup d'espace pour autre chose. Il semblait donc y avoir un problème avec l'apprentissage hebbien.

Ce problème devient moins problématique, cependant, lorsque nous comprenons que la reconnaissance n'est pas un rappel. C'est-à-dire qu'un sentiment de familiarité lorsqu'on voit une image peut se produire sans l'aptitude à régénérer cette image à partir de zéro. Le réseau de Hopfield est remarquable pour sa capacité à accomplir la tâche plus difficile – il complète pleinement un souvenir à partir d'une partie de celui-ci. Mais la tâche première reste importante. Grâce aux chercheurs travaillant à l'Université de Bristol, on sait maintenant que la reconnaissance peut également être effectuée par un réseau utilisant l'apprentissage hebbien. Ces réseaux, lorsqu'ils sont évalués sur leur capacité à étiqueter une entrée comme nouvelle ou familière, ont une capacité significativement plus élevée : 1 000 neurones peuvent maintenant reconnaître jusqu'à 23 000 images. Comme Semon l'a si justement identifié, ceci est un exemple d'un problème qui se pose lorsqu'on repose sur le langage commun pour définir les fonctions du cerveau. Ce que nous ressentons comme simplement « la mémoire » se disloque lorsque la science et les mathématiques l'analysent en une multitude de compétences différentes.

* * *

Lorsqu'en 1953, le docteur américain William Scoville a retiré le hippocampe des deux côtés du cerveau d'un homme de 27 ans nommé Henry Molaison, il

Il pensait qu'il aidait à prévenir les convulsions de Molaison. Mais Scoville ne savait pas que cette procédure aurait un impact incroyable sur la science de la mémoire. Molaison (plus connu sous le nom « H.M. » dans les articles scientifiques pour cacher son identité jusqu'à sa mort en 2008) a trouvé un peu de soulagement à ses convulsions après la procédure, mais il n'a jamais formé une autre mémoire consciente.

L'amnésie permanente et subséquente de Molaison a initié une série de recherches qui ont mis l'accent sur le rôle du hippocampe – une structure en forme de doigt courbe profondément située dans le cerveau – comme un hub dans le système de formation de la mémoire. En évitant la recherche troublée de Lashley, cette zone joue bien sûr un rôle spécial dans la conservation des souvenirs.

Les théories actuelles sur la fonction hippocampale sont les suivantes : l'information sur le monde arrive d'abord au hippocampe à la dentate gyrus, une région qui court le long du bord inférieur du hippocampe. Ici, la représentation est prête et préparée pour être sous forme plus susceptible de stockage de mémoire. La dentate gyrus envoie ensuite des connexions sur où se forment les attracteurs, une zone appelée CA3 ; CA3 a des connexions récurrentes étendues qui le rendent un substrat premier pour les effets réseau Hopfield comme. Cette zone envoie ensuite l'information de sortie à une autre région appelée CA1, qui agit comme un relais ; il envoie l'information mémorisée vers le reste du cerveau (voir la figure 10).

<!-- Début du texte de l'image -->

CA1 "i Le reste
du cerveau
Gyrus denté y |
CA3 dans Gyrus
<!-- Fin du texte de l'image -->

enclosures – un cercle circulaire et un carré. Les neurones hippocampiques montraient un modèle d'activité lorsqu'ils étaient dans le cercle, et un autre modèle lorsque ils étaient dans le carré. Le test des attracteurs a eu lieu lorsque les animaux ont été placés dans un nouvel environnement « squircle », dont la forme se situait entre un cercle et un carré. Les chercheurs ont trouvé que si l'environnement était plus proche d'un carré, l'activité neuronale allait vers le modèle associé au carré ; plus proche d'un cercle et il allait vers celui du cercle. C'est crucial que les représentations intermédiaires n'aient pas été trouvées en réponse à des environnements intermédiaires, mais uniquement tous les cercles ou tous les carrés. Cela fait que les souvenirs des environnements circulaire et carré sont des attracteurs. Une entrée initiale qui n'est pas exactement l'un ou l'autre est instable ; elle se dirige inévitablement vers la mémoire établie la plus proche.

Le réseau d'Hebb fait apparaître les théories de Hebb et montre comment les attracteurs – normalement étudiés en physique – peuvent expliquer les mystères de la mémoire. Cependant, Hopfield connaissait les limites de l'application des mathématiques à des cerveaux réels dans des laboratoires réels. Il a décrit son propre modèle comme une « parodie mineure des complexités de la neurobiologie ». En effet, comme création d'un physicien, il manque de toute la richesse gluante de la biologie. Mais en tant que parodie capable de puissants calculs, elle a offert de nombreuses intuitions aussi – des intuitions qui ne se sont pas arrêtées à un simple stockage et rappel.

* * *

Vous êtes assis à dîner dans votre cuisine lorsque votre colocataire rentre chez lui. Lorsque vous le voyez, vous vous souvenez que la veille vous aviez terminé un livre qu'il vous avait prêté et vous voulez le rendre avant qu'il parte pour un voyage le lendemain. Alors, vous posez vos couverts, sortez de la cuisine et descendez le couloir. Vous marchez jusqu'à l'étage, tournez, entrez dans votre chambre et pensez : « Attends, pourquoi suis-je ici ? »

La sensation est commune au point d'avoir été donné un nom : « destinesia » ou amnésie sur la raison pour laquelle vous êtes allé là où vous êtes. C'est un échec de ce qui s'appelle la « mémoire de travail », capacité à retenir une idée en tête, même juste pendant les 10 secondes qu'il faut pour marcher d'une pièce à l'autre. La mémoire de travail est cruciale pour presque tous les aspects de la cognition : il est difficile de prendre une décision ou de travailler sur un plan si vous continuez à oublier ce dont vous pensez.

Les psychologues étudient la mémoire de travail depuis des décennies. Le terme lui-même a été créé pour la première fois dans le livre *Plans et la structure du comportement* publié en 1960 par George A. Miller et ses collègues scientifiques travaillant au Centre d'études avancées en sciences du comportement en Californie. Mais le concept était exploré bien avant cela. En effet, Miller lui-même a écrit l'un des articles les plus influents sur ce sujet quatre ans auparavant, en 1956. Peut-être anticipant sa célébrité, Miller a donné à l'article un titre badin : 'Le nombre magique sept, plus ou moins deux'. Ce nombre magique fait référence au nombre d'items que les humains peuvent conserver dans leur mémoire de travail en même temps.

Un exemple de la façon d'évaluer ceci est de 1) montrer à un participant plusieurs carrés coloriés sur une écran ; 2) demander-leur de patienter pendant quelques secondes à quelques minutes ; 3) puis leur montrer un deuxième ensemble de carrés coloriés. La tâche du sujet est d'indiquer si les couleurs du deuxième ensemble sont les mêmes que celles du premier. Les gens peuvent faire bien cette tâche si le nombre de carrés affiché reste petit, atteignant presque 100% d'exactitude si seulement un carré est montré. L'ajout de plus de carrés fait chuter la performance et chuter jusqu'à sept, il est presque aussi mauvais que deviner au hasard. Quelques études trouvent des limites inférieures, d'autres supérieures ; cependant, il n'y a aucun doute que l'article de Miller a eu un impact et les psychologues ont travaillé pour caractériser presque tous les aspects de la mémoire de travail depuis, de ce qui peut y être retenu à combien de temps cela peut durer.

Mais la question demeure de savoir comment le cerveau effectue réellement cela : où sont les souvenirs en cours stockés et de quelle manière ? Une méthode éprouvée pour répondre à de telles questions – les expériences d'ablation – a mis en évidence le cortex préfrontal, une grande partie du cerveau située juste derrière la frontière. Que ce soit des humains avec des blessures malheureuses ou des animaux de laboratoire dont l'aire était supprimée, il était clair que les dommages au cortex préfrontal réduisaient considérablement la mémoire de travail. Sans elle, les animaux ont du mal à retenir une idée pendant plus d'une seconde ou deux. Les pensées et les expériences passent par leurs esprits comme l'eau qui passe entre les mains en coupe.

Avec un « X » marquant la zone, les neuroscientifiques ont commencé à creuser. En introduisant une électrode dans le cortex préfrontal des singes, en 1971, des chercheurs de l'Université de Californie à Los Angeles ont écouté les neurones ****là****. Les scientifiques, Joaquin Fuster et Garrett Alexander, ont fait cela pendant que les animaux effectuaient une tâche similaire au test de mémoire de couleur. Ces tests sont connus sous le nom de « tâches de réponse différée » car ils incluent une période de retard où l'information importante est absente de l'écran et doit donc être retenue en mémoire. La question était : qu'est-ce que les neurones du cortex préfrontal font pendant cette période de retard ?

La plupart des régions cérébrales responsables de la vision ont une réponse stéréotypée à ce type de tâche : les neurones répondent fortement lorsque les motifs sur l'écran apparaissent initialement et puis encore lorsqu'ils réapparaissent après le délai, mais pendant la période de délai – quand aucune entrée visuelle n'entre vraiment dans le cerveau – ces régions sont pour la plupart silencieuses. En fait, ce que signifie "hors de vue" est bien hors de l'esprit pour ces neurones. Cependant, Fuster et Alexander ont trouvé que les cellules de la couche préfrontale étaient différentes. Les neurones qui y répondent aux motifs visuels continuaient à fonctionner même après que les motifs avaient disparu ; c'est-à-dire qu'ils maintenaient leur activité pendant la période de délai. Une signature physique du travail de la mémoire de travail !

Des expériences innombrables ont répété ces constatations depuis, montrant une activité maintenue pendant les périodes de retard dans de nombreuses circonstances différentes, à la fois dans le cortex préfrontal et au-delà. Les expériences ont également suggéré que lorsque ces modèles d'activation sont en déséquilibre, la mémoire de travail se met en danger. Dans certaines expériences par exemple, l'application d'une stimulation électrique brève pendant la période de retard peut perturber l'activité en cours et cela conduit à une baisse du rendement sur les tâches de réponse différée. Qu'est-ce qui est si spécial chez ces neurones qu'ils puissent faire cela ? Pourquoi peuvent-ils conserver l'information et maintenir leur activation pendant des secondes ou des minutes, alors que d'autres neurones laissent tomber la leur ? Pour ce genre d'output soutenu, les neurones ont besoin de stimuli soutenus. Mais si l'activité de retard se produit sans aucune entrée externe depuis une image, alors le stimulus doit provenir des neurones voisins. Par conséquent, l'activité de retard ne peut être générée que par un réseau de neurones travaillant ensemble, les connexions entre eux conspirant pour maintenir l'activité en vie. C'est là que l'idée d'attracteurs revient en jeu.

Jusqu'à présent, nous avons examiné les attracteurs dans les réseaux Hopfield, qui montrent comment les signaux d'entrée rallument une mémoire. Il peut ne pas être clair de savoir comment cela aide la mémoire de travail. Après tout, la mémoire de travail est tout ce qui se passe après cette ignition ; après que vous vous êtes levé pour aller chercher le livre de votre colocataire, comment faites-vous

garder cela en tête ? Cependant, il s'avère que ce qui est nécessaire dans cette situation est exactement un attracteur, car un attracteur reste en place.

Les attracteurs sont définis par les dérivées. Si nous savons les entrées d'un neurone et le poids de ces entrées multipliées par elles, nous pouvons écrire une équation – une dérivée – décrit comment l'activité de ce neurone changera au fil du temps en raison de ces entrées. Si cette dérivée est zéro, cela signifie qu'il n'y a pas de changement dans l'activité du neurone au fil du temps ; il continue simplement à tirer à la même vitesse constante. Rappelez-vous que, puisque ce neurone fait partie d'un réseau récurrent, il ne reçoit pas seulement des entrées mais sert également d'entrée pour d'autres neurones. Ainsi, son activité entre dans le calcul de la dérivée d'un neurone voisin. Si aucune des entrées de ce neurone voisin ne changent – c'est-à-dire que toutes leurs dérivées sont aussi zéro – alors il aura également une dérivée nulle et continuera à tirer à la même vitesse.

Lorsqu'un réseau est dans un état attracteur, la dérivée de chaque neurone de ce réseau est zéro.

Et c'est ainsi que, si les connexions entre les neurones sont juste bonnes, les souvenirs commencés à un moment donné peuvent durer plus longtemps. Tous les cellules maintiennent leur taux de tirage car toutes les cellules autour d'elles font la même chose. Rien ne change si rien ne change.

Le problème est que les choses changent en fait. Lorsque vous quittez la cuisine et marchez jusqu'à votre chambre à coucher, vous rencontrez toutes sortes de choses – vos chaussures dans le hall, la salle de bain que vous aviez l'intention de nettoyer, la vue de la pluie sur la fenêtre – qui pourraient causer des changements dans les entrées aux neurones qui essaient de retenir la mémoire. Et ces changements pourraient pousser les neurones hors de l'état attracteur représentant le livre et les envoyer ailleurs en tout entier. Pour que la mémoire de travail fonctionne, le réseau doit être bon à résister à l'influence de tels distractions. Un attracteur ordinaire peut résister à une certaine mesure aux entrées distrayantes. Rappelez-vous l'exemple du trampoline. Si la personne debout sur le trampoline donnait un petit coup au ballon, il serait probablement roulé juste hors de son divot et puis rentrer. Avec une petite perturbation seulement, la mémoire reste intacte, mais donnez au ballon un bon coup et on ne sait pas où il ira finalement ? Une bonne mémoire devrait être robuste à de telles distractions – donc quoi pourrait rendre un réseau capable de retenir des souvenirs ?

La danse entre les données et la théorie est une chose complexe, avec aucun leader clair ou suivant. Parfois, des modèles mathématiques sont développés uniquement pour s'adapter à un certain jeu de données. D'autres fois, les détails provenant des données sont absents ou ignorés et les théoriciens

élaborer des hypothèses sur la manière dont un système *_pourrait_* fonctionner avant de connaître la réalité. Lorsqu'il s'agit de construire un réseau robuste pour la mémoire de travail, les scientifiques des années 1990 sont allés dans cette direction. Ils ont conçu ce qu'on appelle le "réseau en anneau", une modélisation manuelle d'un circuit neuronal qui serait idéal pour le maintien robuste des souvenirs de travail.

Contrairement aux réseaux de Hopfield, les réseaux en anneau sont bien décrits par leur nom : ils sont composés de plusieurs neurones disposés en un anneau, avec chaque neurone se connectant uniquement à ceux qui lui sont proches. Comme les modèles de réseau de Hopfield, ces modèles ont des états attracteurs – des motifs d'activité auto-soutenus qui peuvent représenter des souvenirs. Mais les états attracteurs dans un modèle en anneau sont différents de ceux d'un réseau de Hopfield. Les attracteurs dans un modèle de Hopfield sont *_discrets_*. Cela signifie que chaque état attracteur – celui de votre chambre enfantine, celui de vos vacances enfantines, celui de votre chambre actuelle – est entièrement isolé les uns des autres. Il n'y a pas de manière fluide pour passer entre ces différents souvenirs ; vous devez complètement quitter un état attracteur pour atteindre un autre. Les attracteurs dans un réseau en anneau, d'autre part, sont *_continus_*. Avec des attracteurs continus, il est facile de passer entre des souvenirs similaires. Au lieu de penser à une trampoline avec des personnes debout à différents points, les modèles avec des états attracteurs continus sont plus comme le rebord d'une piste de bowling : une fois que la balle se met dans le rebord, elle ne peut pas facilement en sortir, mais elle peut se déplacer de manière fluide au sein de celui-ci.

Les réseaux avec des états d'attraction continu comme le modèle en anneau sont utiles pour plusieurs raisons et la principale est le type d'erreurs qu'ils commettent. Il peut sembler ridicule de louer un système de mémoire pour ses erreurs – ne voudrions-nous pas que tout soit parfait ? – mais si on suppose que aucun réseau ne peut avoir une mémoire parfaite, alors la qualité des erreurs devient très importante. Un réseau en anneau permet des erreurs petites et sensées.

Considérons l'exemple du test de mémoire de travail où les sujets devaient garder à l'esprit la couleur des formes sur un écran. Les couleurs se mappent bien aux réseaux en anneau car, comme vous le rappelez peut-être depuis votre cours d'art, les couleurs sont disposées en cercle. Imaginez donc un réseau de neurones disposés en anneau, chaque neurone représentant une couleur légèrement différente. Du côté gauche de l'anneau se trouvent des neurones représentant le rouge, à côté d'eux se trouvent ceux qui représentent l'orange, puis le jaune et le vert ; cela nous amène au côté opposé du rouge où se trouvent les neurones représentant le bleu, ce qui mène aux violettes et enfin au rouge.

Dans cette tâche, lorsqu'une forme est observée, elle crée une activité dans les neurones qui représentent sa couleur, tandis que les autres neurones restent silencieux. Cela crée un petit «bump» d'activité sur l'anneau, centré sur la couleur mémorisée. Si des entrées distrayantes arrivent pendant que le sujet essaie de retenir cette mémoire de couleur – par exemple, d'autres vues aléatoires dans la pièce – elles peuvent pousser ou tirer le «bump» d'activité loin de la couleur souhaitée. Mais – et c'est là le point crucial – il ne pourra les pousser que dans un endroit très proche sur l'anneau. Ainsi, le rouge peut devenir rouge-orange ou le vert peut devenir bleu-vert. Mais la mémoire du rouge serait très peu probable de devenir verte. Ou, pour faire une autre remarque, elle ne deviendrait pas non plus couleur nulle ; c'est-à-dire qu'il y aura toujours un «bump» *quelconque* sur l'anneau. Ces propriétés sont toutes le résultat direct de la nature en forme de gouttière d'un attracteur continu – il a une faible résistance pour se déplacer entre des états proches, mais une forte résistance aux perturbations dans les autres cas.

Un autre avantage du réseau en anneau est qu'il peut être utilisé pour faire des choses. Le «travail» en mémoire de travail est censé contrecarrer l'idée selon laquelle la mémoire n'est que de maintenir passivement de l'information. Au contraire, retenir les idées dans la mémoire de travail nous permet de les combiner avec d'autres informations et d'en venir à de nouvelles conclusions. Un exemple excellent de cela est le système de direction de tête des rats, qui a également servi d'inspiration pour les premiers modèles de réseau en anneau.

Les rats (ainsi que de nombreux autres animaux) ont un compas interne : un ensemble de neurones qui suivent la direction dans laquelle l'animal se trouve à tout moment. Si l'animal tourne pour regarder une nouvelle direction, l'activité de ces cellules change pour refléter ce changement. Même si le rat reste assis dans une pièce sombre et silencieuse, ces neurones continuent d'émettre des signaux, gardant en mémoire la direction qu'il était face.

En 1995, un équipe du laboratoire de Bruce McNaughton à l'Université de l'Arizona et, séparément, Kechen Zhang de l'Université de Californie, San Diego, ont proposé que cet ensemble de cellules pouvait être bien décrit par un réseau en anneau. La direction étant l'un de ces concepts qui se cartographient bien sur une circonférence, une bosse d'activité sur le cercle serait utilisée pour stocker la direction dans laquelle l'animal était face (Voir la Figure 11).

Mais non seulement un réseau en anneau pouvait expliquer comment les connaissances de la direction de la tête étaient maintenues au fil du temps, mais il servait également de modèle sur comment la direction stockée pouvait changer lorsque l'animal le faisait. Les cellules de direction de la tête reçoivent des entrées d'autres neurones, tels que ceux du système visuel et

<!-- Début du texte de l'image -->

Direction de la Tête Direction de la Tête
Neurones
oP oe
Activité élevée Y
Activité moyenne
Aucune activité oO
Oo
we) ' =
%
\
<!-- Fin du texte de l'image -->

la connectivité entre les neurones, des hypothèses qui semblent tout à fait irréalistes. Ainsi, malgré toutes leurs propriétés théoriques désirables et leurs capacités utiles, les chances de voir un réseau en anneau dans le cerveau semblaient minces.

La découverte faite dans un centre de recherche situé juste à l'extérieur de Washington DC en 2015 était donc encore plus excitante.

Le Janelia Research Campus est une installation de recherche de classe mondiale cachée dans les anciens champs d'Ashburn, en Virginie. Vivek Jayaraman a été au Janelia depuis 2006. Lui et son équipe d'environ six personnes travaillent pour comprendre la navigation chez *Drosophila melanogaster*, une espèce de mouche à fruit couramment étudiée en neurosciences. Avec la taille d'une graine de riz, la taille de ces animaux est à la fois un don et une malédiction. Alors qu'ils peuvent être difficiles à attraper, ces petits insectes n'ont que 135 000 neurones environ, soit environ 0,2 % du nombre de neurones d'un autre animal de laboratoire populaire, le souris. En plus de cela, beaucoup sont connus sur ces neurones. Beaucoup d'entre eux peuvent être facilement classés en fonction des gènes qu'ils expriment, et leur nombre et leurs emplacements sont très similaires chez les individus.

Comme les rongeurs, les mouches ont également un système pour suivre la direction de la tête. Pour la mouche, ces neurones de direction de tête se trouvent dans une région appelée le corps ellipsoïdal. Le corps ellipsoïdal est placé en centre du cerveau de la mouche et il a une forme unique : il a un trou au milieu avec des cellules disposées tout autour de ce trou, formant un doughnut fait de neurones – ou pour le dire autrement, un anneau.

Les neurones disposés en anneau ne font pas nécessairement un réseau en anneau. Par conséquent, ce que le laboratoire Jayaraman a cherché à faire était d'investiguer si ce groupe de neurones qui semblaient être un réseau en anneau, agissaient vraiment comme l'un.

Pour cela, ils ont mis une teinture spéciale dans les neurones du corps ellipsoïdal, celle-ci fait qu'ils s'éclairent en vert lorsqu'ils sont actifs. Ils ont ensuite laissé l'insecte marcher autour de lui tout en filmant les neurones. Si vous regardiez ces neurones sur un écran, alors que l'insecte se dirigeait vers l'avant, vous verriez une alternance rapide de petits points verts à une seule localisation sur un écran noir.

Si l'insecte choisissait de faire un virage, cette zone clignotante serait en mouvement et passerait à une nouvelle localisation. Au fil du temps, alors que l'insecte se déplace et que le patch vert sur l'écran bouge avec lui, les points qui s'étaient allumés forment une structure circulaire nette, correspondant à la forme sous-jacente du corps ellipsoïdal.

Si vous éteignez les lumières dans la pièce de sorte que l'insecte n'ait pas la capacité de savoir dans quelle direction il se dirige, le clignotement vert reste toujours à la même localisation sur ce cercle – un signe clair que la mémoire de la direction d'orientation est maintenue.

En plus d'observer l'activité sur l'anneau, les expérimentateurs ont également manipulé celui-ci afin de tester les extrêmes de son comportement. Un vrai réseau en anneau ne peut supporter qu'un seul « coup » d'activité ; c'est-à-dire que seuls les neurones situés à une seule localisation sur l'anneau peuvent être actifs à un moment donné. Par conséquent, les chercheurs ont stimulé artificiellement des neurones du côté opposé de l'anneau par rapport à ceux qui étaient déjà actifs. Cette forte stimulation des neurones opposés a fait fermer le coup d'origine et maintenu celui situé à la nouvelle localisation même après que la stimulation ait été arrêtée. À travers ces expériences, il est devenu clair que l'ellipse corporelle n'était pas un imposteur, mais un exemple vivant d'une théorie qui s'est réalisée.

Cette découverte – un réseau en anneau dans sa forme littérale et visible – ressemble un peu à nature nous faire un clin d'œil. William Skaggs et les autres auteurs de l'un des premiers articles proposant le réseau en anneau ont explicitement douté de la possibilité de telles découvertes : « Pour des fins expositives, il est utile de penser au réseau comme à un ensemble de couches circulaires ; cela ne reflète pas l'organisation anatomique correspondante des cellules dans le cerveau. » La plupart des théoriciens travaillant sur les modèles de réseaux en anneau ont supposé qu'ils seraient insérés dans un réseau plus large et plus complexe de neurones. Et cela est probablement le cas pour la plupart des systèmes dans la plupart des espèces. Cet exemple anormalement pur provient probablement d'un programme génétique très précisément contrôlé. Les autres seront beaucoup plus difficiles à détecter.

Même si nous ne pouvons généralement pas les voir directement, nous pouvons faire des prédictions sur le comportement que l'on attendrait de voir si le cerveau utilise des attracteurs continus. En 1991, la chercheuse pionnière en mémoire de travail Patricia Goldman-Rakic a découvert que bloquer la fonction du neuromodulateur dopamine rendait plus difficile aux singes de se rappeler l'emplacement d'objets. La dopamine est connue pour modifier le flux d'ions entrant et sortant d'une cellule. En 2000, des chercheurs à l'Institut Salk en Californie ont montré comment imiter la présence de dopamine dans un modèle avec un attracteur continu améliorerait la mémoire du modèle. Cela stabilisait l'activité des neurones codant la mémoire, les rendant plus résistants aux entrées non pertinentes. Puisque la dopamine est associée à la récompense, ce modèle prédit également que dans des conditions où une personne s'attend à recevoir une grande récompense pour se rappeler quelque chose, sa mémoire de travail sera meilleure – et c'est exactement ce qui a été trouvé. Lorsque les gens sont promis plus de récompenses en échange de se rappeler quelque chose, leur mémoire de travail est meilleure. Ici, le concept d'un attracteur fonctionne comme la trame qui relie les changements chimiques aux expériences. Cela relie les ions aux expériences.

Les attracteurs sont omniprésents dans le monde physique. Ils découlent des interactions locales entre les parties d'un système. Que ces parties soient des atomes dans un métal, des planètes dans un système solaire ou même des personnes dans une communauté, elles seront contraintes vers un état attracteur et, sans perturbations majeures, y resteront. L'application de ces concepts aux neurones qui forment une mémoire relie les points entre la biologie et la psychologie. D'un côté, les réseaux de Hopfield lient la formation et la récupération des souvenirs à la manière dont les connexions entre les neurones changent. De l'autre, des structures comme les réseaux en anneau sous-tendent la façon dont les idées sont retenues dans la mémoire. Dans un cadre simple, nous capturons comment les souvenirs sont enregistrés, conservés et réactivés.

****Notes****

- 1 Jerzy Konorski, un neurophysiologiste polonais, a publié un livre avec des idées très similaires l'année avant que Hebb ne le fasse. En fait, Konorski a anticipé plusieurs découvertes importantes en neuroscience et psychologie. Cependant, la division Est-Ouest mondiale à l'époque isolait ses contributions.
- 2 Lorsque Hopfield a écrit sur un formulaire d'admission universitaire qu'il avait l'intention de faire des études de « physique ou de chimie », son conseiller universitaire – un collègue de son père – a barré la dernière option en disant : « Je ne pense pas que nous devons considérer la chimie. »
- 3 L'attitude de Hopfield n'était pas unique. Les années 1980 ont trouvé de nombreux physiciens, ennuyés par leur propre domaine, regardant le cerveau et pensant : « Je pourrais résoudre cela. » Après la réussite de Hopfield, cette population a encore augmenté.
- 4 Alors que le calcul de l'activité d'un neurone individuel en termes d'entrées et de poids est le même que décrit pour le perceptron dans le dernier chapitre, le perceptron est un *_réseau feedforward_* (pas récurrent). La récurrence signifie que les connexions peuvent former des boucles : le neurone A se connecte au neurone B, qui se reconnecte à son tour au neurone A, par exemple.
- 5 Cette deuxième partie – l'idée selon laquelle la force de connexion devrait *_diminuer_* si un neurone pré-synaptique est très actif tandis que le neurone post-synaptique reste silencieux – n'était pas partie du schéma original de Hebb, mais elle a depuis été confirmée par des expériences.
- 6 En fait, lorsqu' Hopfield a présenté une version préliminaire de ce travail à un groupe de neuroscientifiques, un participant a commenté que « c'était un beau discours mais malheureusement sans rapport avec la neurobiologie » .
- 7 Vous connaissez peut-être des gens qui ont leur propre histoire de « catastrophe noire » après une nuit de boisson. Cependant, le type précis de perte de mémoire observé dans les réseaux Hopfield n'est pas vraiment censé se produire chez l'homme.
- 8 Ce processus est censé se produire pendant la sommeil.
- 9 Ce modèle était composé de neurones du style Hodgkin-Huxley décrit au chapitre 2, ce qui facilite l'intégration des effets du dopamin sur les flux d'ions.
- Dix lots d'autres informations sur ce sujet sont présentées au Chapitre 11 !

CHAPITRE CINQ